

Deployable-only Offline RL Closes the Privileged-Critic Gap on Underwater Wake Navigation

Anonymous Authors

(submitted to CoRL / RA-L; double-blind)

摘要

我们在水下 AUV wake field 导航这一 sim2real 任务上, 提出 **ReBRAC-Q** (一个 Q-normalized dual-penalty TD3+BC 变体), 用部署友好的单点 DVL 水流测速 (deployable-only) 协议把离线策略性能拉到与 privileged-critic 协议统计意义上不可区分的水平: 在 **worldcomp-1000** 上 deployable-only ReBRAC-Q 取得 0.928 ± 0.077 success rate, 与 privileged-critic TD3+BC (0.922 ± 0.086) 的 Welch’s t -test $p = 0.92$; 在 **crosscomp** 上 ReBRAC-Q 比 TD3+BC 提升 **+23.0/+32.2pp**, 且翻转 TD3+BC “2000 < 1000” 的 anti-scaling 退化。机制上, actor-side BC penalty 主导 mean uplift, critic-side BC penalty 不抬 mean 但通过 target-Q bootstrap 抑制 Q 高估、并对 outlier seed 提供 dataset-invariant 的稳定性; critic LayerNorm 与 dual penalty 是两个独立必要 component (LN-off 退化 -16.2pp、 $\hat{Q}$ 漂移方向相反)。这一结果意味着, 在水下 AUV 这种 deployable sensor 严格受限的部署设置下, 离线 RL 可以不依赖任何 privileged simulator 信号就把性能逼近 online teacher。

1 方法: Q-normalized dual-penalty TD3+BC variant

1.1 算法名称与定位

我们把本文的离线 RL 算法记为 **Q-normalized dual-penalty TD3+BC variant** (别名 **ReBRAC-Q**)。其实现路径如下: 在 Fujimoto and Gu [2021] 提出的 TD3+BC actor loss 形式 (确定性策略梯度项被 batch-mean $|Q|$ 归一化; 详见 §1.2) 之上, 叠加 Tarasov et al. [2023] 在 ReBRAC 中提出的 minimal recipe ——

actor / critic 双侧 BC penalty 与 critic LayerNorm。

关键诚信声明。 ReBRAC-Q 不是原版 ReBRAC 的复刻: Tarasov et al. [2023] 原版 actor 不做 Q normalization。因此本文给出的 β_1, β_2 数值与 Tarasov et al. [2023] 的同名超参**不可直接对比**。我们在 §1.4 给出与原版 ReBRAC 的逐项对比表, 并在 §1.5 给出与 TD3+BC 的等价关系 ($\beta_1 = 4.0 \leftrightarrow \alpha_{\text{TD3+BC}} \approx 0.25$)。文中所有数值超参对比仅在我们自行训练、协议一致的 TD3+BC baseline 之间进行。

1.2 Actor loss

设 $\pi_\theta(s)$ 为确定性 actor, $Q_\phi(s, a)$ 为 twin-critic 取最小后的输出。对每个 mini-batch $\mathcal{B} = \{(s, a)\}$ 抽自 offline buffer, 定义 batch-level 的 detached $|Q|$ 标量

$$\bar{Q} := \text{mean}_{(s, \cdot) \in \mathcal{B}} [Q_\phi(s, \pi_\theta(s))] \cdot \text{detach}(), \quad (1)$$

以及 Q-normalization 系数

$$\lambda = \frac{1}{\max(\bar{Q}, \varepsilon)}, \quad \varepsilon = 10^{-6}. \quad (2)$$

$\bar{Q}$ 参与 forward 但不回传梯度 (“ $\text{detach}()$ ”); ε 给 $\bar{Q}$ 设下界, 防止训练早期 $\bar{Q} \rightarrow 0$ 时 λ 数值爆炸 (实现等价: “ $|Q| \cdot \text{abs}().\text{mean}().\text{detach}().\text{clamp_min}(\varepsilon).\text{reciprocal}()$ ”))。

Actor loss 为:

$$\mathcal{L}_{\text{actor}}(\theta) = -\lambda \cdot \mathbb{E}_{(s, \cdot) \sim \mathcal{B}} [Q_\phi(s, \pi_\theta(s))] + \beta_1 \cdot \mathbb{E}_{(s, a) \sim \mathcal{B}} [\|\pi_\theta(s) - a\|^2] \quad (3)$$

第一项是 Q-normalized 的确定性策略梯度项; 第二项是 BC penalty, 在状态 s 上把 actor 输出 anchor 到行为策略采样过的动作 a 。

1.3 Critic loss

Critic 端继承 ReBRAC 的双侧惩罚结构。对 transition (s, a, r, s') 与 twin critic Q_{ϕ_1}, Q_{ϕ_2} 、target actor π_θ 、

表 1: ReBRAC-Q (本文) 与 **original ReBRAC** [Tarasov et al., 2023] 的逐组件对比。唯一差异在 actor 端 Q normalization。

Component	Original ReBRAC	ReBRAC-Q (ours)
Actor Q term scaling	$-\mathbb{E}[Q]$ (不归一化)	$-\frac{1}{\beta_1 \cdot \max(\bar{Q}, \varepsilon)} \cdot \mathbb{E}[Q]$
Actor BC penalty	$\beta_1 \cdot \mathbb{E}[\ \pi - a\ ^2]$	同左
Critic loss	$\text{TD3} + \beta_2 \cdot \mathbb{E}[\ a' - \pi_{\bar{\theta}}(s')\ ^2]$	同左
Critic LayerNorm	默认 on	默认 on (winner)
Policy update frequency	每 2 次 critic update 更新一次 actor	同左
Target smoothing	next action 上加 clipped Gaussian 噪声	同左

target critic $Q_{\bar{\phi}_1}, Q_{\bar{\phi}_2}$, 按 TD3 风格构造 next-action target:

$$a' = \pi_{\bar{\theta}}(s') + \text{clip}(\eta, -c, c), \quad \eta \sim \mathcal{N}(0, \sigma^2 \mathbf{I}), \quad (4)$$

$$y(s, a, r, s') = r + \gamma(1 - d) \min_{j \in \{1, 2\}} Q_{\bar{\phi}_j}(s', a'), \quad (5)$$

其中 d 为 episode 终止指示, c 与 σ 分别是 target smoothing 的截断与噪声标准差。Critic loss 为:

$$\mathcal{L}_{\text{critic}}(\phi) = \mathbb{E}[(Q_{\phi}(s, a) - y(s, a, r, s'))^2] + \beta_2 \cdot \mathbb{E}[\|a' - \pi_{\bar{\theta}}(s')\|^2] \quad (6)$$

其中 critic-side BC penalty $\beta_2 \cdot \|a' - \pi_{\bar{\theta}}(s')\|^2$ 是 ReBRAC 相较 TD3+BC 的核心改动; 它通过 target-Q bootstrap 链路抑制 actor 在 OOD 区域的 Q 高估 (§2.2.3 给出 cross-dataset Q-drift 的实证)。

1.4 与原版 ReBRAC 的差异

表 1 逐行对比 ReBRAC-Q 与原版 ReBRAC [Tarasov et al., 2023]: 唯一差异在 actor loss 第一项是否引入 $\lambda = 1/\max(\bar{Q}, \varepsilon)$ 的归一化 (参见 (2)); 其他全部 component (actor/critic BC penalty 公式、critic LayerNorm、policy update frequency、TD3 target smoothing) 逐项一致。

1.5 与 TD3+BC 的等价关系

Fujimoto and Gu [2021] 原版 TD3+BC actor loss 为:

$$\mathcal{L}_{\text{actor}}^{\text{TD3+BC}}(\theta) = -\lambda_{\text{TD3+BC}} \cdot \mathbb{E}[Q_{\phi}(s, \pi_{\theta}(s))] + \mathbb{E}[\|\pi_{\theta}(s) - a\|^2] \quad (7)$$

将本文 actor loss (3) 整体除以 β_1 得到等价的 BC-penalty-单位化形式:

$$\frac{\mathcal{L}_{\text{actor}}}{\beta_1} = -\frac{1}{\beta_1 \cdot \max(\bar{Q}, \varepsilon)} \cdot \mathbb{E}[Q] + \mathbb{E}[\|\pi - a\|^2]. \quad (8)$$

对照 (7) 与 (8), BC anchoring 强度的等价关系为:

$$\alpha_{\text{TD3+BC}} \approx \frac{1}{\beta_1}. \quad (9)$$

本文 winner 取 $\beta_1 = 4.0$, 对应 $\alpha_{\text{TD3+BC}} \approx 0.25$, 恰好与我们在 crosscomp 数据上自行扫出的 TD3+BC baseline winner $\alpha = 0.25$ 重合 (见 §2.1)。这一重合为 §2.2.1 中报告的 +23.0/+32.2pp 跃升提供了 “actor 端 BC anchor 强度等同、唯一改动是引入 critic-side 双侧惩罚” 的纯净对照。

ReBRAC-Q 相对 TD3+BC 的关键算法增量是:

1. **Critic-side BC penalty** $\beta_2 \cdot \|a' - \pi_{\bar{\theta}}(s')\|^2$ ((6) 第二项);
2. **Critic LayerNorm** (默认 on, 与 Tarasov et al. [2023] 一致)。

两者的独立必要性分别由 §2.2.3 与 §2.2.4 实证。

1.6 实现注记 (Implementation note)

本文 actor loss 的实现保留了 TD3+BC 风格的 Q normalization $\lambda = 1/\max(\bar{Q}, \varepsilon)$ (参见 (1)–(2)) 作用在确定性策略梯度项上。报告中 $\beta_1 = 4.0$ 是 BC penalty 的绝对系数, 对应我们超参网格 $\beta_1 \in \{1.0, 2.0, 4.0\}$ 中的最强 anchor 档; 与 Tarasov et al. [2023] 中同名超参的数值不可直接对比 ((9) 给出与 TD3+BC α 的等价换算)。本文所有数值超参对比仅在我们自行训练的 TD3+BC baseline 与本文 ReBRAC-Q 之间进行。

1.7 设计动机 (why this variant)

- **保留 Q normalization 的动机.** 不同 dataset 的 Q 量级差异显著 (worldcomp-1000 上 mean $Q \approx +15$ 、crosscomp-1000 上 mean $Q \approx -8$, 符号都相反)。引入 $\lambda = 1/\max(\bar{Q}, \varepsilon)$ 让 actor 的 BC penalty 系数 α 在 dataset 间可移植, 避免每个 dataset 单独扫 β_1 。

- **引入 dual penalty 的动机.** 在 `worldcomp` 与 `crosscomp` 上同时设置 $\beta_2 = 0$, 会让 `mean_target_q` 分别漂 +46% 与 +98% (§2.2.3), 且 seed 44 在 `crosscomp` 上单点崩塌 -17pp。Critic-side BC penalty 因此并非 cosmetic: 它通过 target-Q bootstrap 抑制 actor 在 OOD 区域诱发的 Q 高估。
- **综合效果.** 我们能在 `worldcomp-1000` / `crosscomp-1000` / `crosscomp-2000` 三个 dataset 上报告同一份 winner 配置 $(\beta_1, \beta_2) = (4.0, 2.0)$; 这一 dataset-invariance 性质在不带 Q normalization 的原版 ReBRAC 上不可达成 (需要每个 dataset 单独 retune)。

2 实验

我们围绕三个问题组织实验: (i) 在与 TD3+BC [Fujimoto and Gu, 2021] 完全相同的 deployable canonical protocol 下, ReBRAC-Q 是否稳定优于 TD3+BC? (ii) 在 `worldcomp` 数据上, deployable-only 协议是否需要 privileged-critic 才能逼近 online teacher? (iii) ReBRAC-Q 中 dual penalty 与 critic LayerNorm 各自的独立必要性如何拆分? §2.1 给出协议; §2.2 用四个 finding 回答上述问题; §2.3 给出机制层 ablation。

2.1 实验协议

数据集与 benchmark. 所有实验共用同一个固定 evaluation manifest `single_u10_cross_tgt15.json` (100 episodes、cross-stream 任务、target speed 1.5 m/s、flow wake_v8 Re150 Ti5%)。三个 offline 数据集对应两类 baseline policy 的轨迹收集:

- `crosscomp-1000` / `crosscomp-2000`: cross-compensation baseline 在 1000 / 2000 episodes 下的离线 corpus;
- `worldcomp-1000`: world-compensation (privileged) baseline 在 1000 episodes 下的离线 corpus, 其 deployable→teacher gap 是 `worldcomp` 主线的核心难点。

对照方法.

表 2: 主结果覆盖的 dataset $\times$ protocol 单元 (每个单元 5 seeds $\times$ test=100 episodes)。**D** = deployable-only; **P** = privileged-critic。

Dataset	TD3+BC	ReBRAC-Q (ours)
<code>crosscomp-1000</code>	D	D
<code>crosscomp-2000</code>	D	D
<code>worldcomp-1000</code>	D, P	D, P

- **TD3+BC** [Fujimoto and Gu, 2021]: baseline, `crosscomp` 取 $\alpha = 0.25$ (与 ReBRAC-Q $\beta_1 = 4.0$ 等价; 见 §1); `worldcomp` deployable 取 $\alpha = 0$ (退化为 BC); privileged-critic 取 $\alpha = 0.1$ (与 Authors [2026] 主线一致)。
- **ReBRAC-Q (ours)**: 固定 winner 配置 $\beta_1 = 4.0$, $\beta_2 = 2.0$, hidden = 256, 3 hidden layers, critic LayerNorm *on*, actor LayerNorm *off*, actor-side Q normalization *on* (详见 §1)。
- **Privileged-critic 变体**: actor 永远只看 deployable observation s_0 (10-D, DVL water-track 单点); privileged-critic 协议下 critic 额外接收 hull-integral 等效流 $[u_{eq}, v_{eq}] \in \mathbb{R}^2$ (actor update 时以 zero padding 填充)。Privileged 通道仅在训练时存在, 部署时不可用。

训练与评估. 所有 run 使用 5 random seeds {42, 43, 44, 45, 46}, TRAIN_EPOCHS=64, CHECKPOINT_EVERY_EPOCHS=8。Checkpoint 选择规则严格按 lexicographic order `success_rate` $\rightarrow$ `return` $\rightarrow$ `-safety_cost` $\rightarrow$ `-time` 在 val=40 episodes 上挑选; test 在 100 episodes 上一次性报告, 不再调参。所有判据 (rule 阈值、情景 A/B/C 分档) 在实验启动前 pre-register, 事后不调阈值。**统计约定.** 本文所有 mean $\pm$ std 报告的 std 均为样本标准差 (Bessel correction, divisor $n - 1$), 与 §2.2.2 中 Welch’s *t*-test 内部所用估计量一致。

Dataset $\times$ protocol 矩阵. 表 2 列出主结果覆盖的 6 个 (dataset, protocol) 单元; ablation 在 §2.3 中针对 `crosscomp-1000` 与 `worldcomp-1000` 的 deployable 协议追加 4 个 probe 单元。

表 3: 主对照表 (5 seeds $\times$ test=100)。所有数字以小数形式给出 success rate。 Δ 列以 percentage points (pp) 表示。cross-1000 / cross-2000 / world-1000 分别简记 crosscomp-1000 / crosscomp-2000 / worldcomp-1000。

Dataset	协议	TD3+BC	ReBRAC-Q
<i>Finding 1: crosscomp 大幅领先</i>			
cross-1000	deployable	0.672 $\pm$ 0.050	0.902 $\pm$ 0.024
cross-2000	deployable	0.596 $\pm$ 0.040	0.918 $\pm$ 0.034
<i>Finding 2: worldcomp 上 deployable-only 与 privileged-critic 持平</i>			
world-1000	deployable	0.858 $\pm$ 0.089	0.928 $\pm$ 0.086
world-1000	privileged-critic	0.922 $\pm$ 0.096	0.934 $\pm$ 0.026
<i>Online teacher (reference)</i>		—	0.990

2.2 主结果

2.2.1 Finding 1: ReBRAC-Q 在 crosscomp 上大幅优于 TD3+BC, 且翻转 “2000 < 1000” 退化

表 3 上半部分汇总 crosscomp 上的对比结果。在两个数据预算下, ReBRAC-Q 相对 TD3+BC 分别取得 **+23.0pp** 与 **+32.2pp** 的 mean success rate 提升, 且跨 seed standard deviation 同时不增反降 (0.050 $\rightarrow$ 0.024, 0.040 $\rightarrow$ 0.034) ——“均值改进同时方差不增”这一离线 RL 文献中常被忽视的硬约束在两个 dataset 上同时成立。

更值得注意的是定性翻转: TD3+BC 主线下数据越多反而越差 (0.672 $\rightarrow$ 0.596, -7.6 pp), 而 ReBRAC-Q 上数据越多越好 (0.902 $\rightarrow$ 0.918, $+1.6$ pp)。这表明 dual penalty 与网络容量让算法有能力消化更大的支持集; TD3+BC 没有这种能力。我们在 §?? 中把这一现象与 Tarasov et al. [2023] 提出的 “offline RL 是否能利用更多数据” 区分开。

2.2.2 Finding 2: deployable-only 协议与 privileged-critic 协议在统计上持平

表 3 下半部分对比 worldcomp-1000 上的四个 (method, protocol) 配置。核心结论是 **deployable-only ReBRAC-Q** (0.928 $\pm$ 0.086) 与 **privileged-critic TD3+BC** (0.922 $\pm$ 0.096) 在统计意义下不可区分:

- Welch’s t -test (5 vs 5 seed-level means): $t =$

0.104, $p_{\text{two-sided}} = 0.9195$, 无法拒绝 H_0 ;

- **Paired episode-level bootstrap (10000 resamples):** $\hat{\Delta} = +0.0060$, 95% CI = $[-0.0300, +0.0420]$, 包含 0;

- **Gap closure:** deployable-only ReBRAC-Q 关闭 Δ 的 deployable $\rightarrow$ teacher gap, 与 privileged-critic TD3+BC 的 48.5% 同档。

进一步把 ReBRAC-Q 升级为 privileged-critic 协议后, 5-seed mean 进一步上升到 0.934 $\pm$ 0.026, 但相比 deployable-only 只多 +0.6pp (远小于两侧协议各自的 between-seed σ)。这说明: 在 ReBRAC-Q 上, **privileged-critic 不再贡献 mean 抬升**, 仅贡献 outlier seed 救援。

图 1 给出 5 seeds $\times$ 3 协议的 per-seed success rate。读者应注意 seed 44: 在 deployable-only 下崩到 0.78 (与其他 seeds 的 0.93 $\sim$ 0.99 显著分离), 但在 privileged-critic 下被救回到 0.90 ($+12$ pp); 这一现象在 §2.3.3 与 §?? 中作为 “critic 信息瓶颈” 的关键证据。

Sim2real 含义. 对水下 AUV 这种部署受限场景, “deployable-only 与 privileged-critic 协议在统计意义上等价” 是本文最强的部署友好性论断: actor 与 critic 都只用 DVL water-track 单点采样, 不依赖任何 simulator-only 的 hull-integral 信号, 仍可逼近 online teacher 的 99% 成功率 (53% gap closure)。

2.2.3 Finding 3: dual penalty 是 dataset-invariant 的必要组件

为了验证 critic-side BC penalty β_2 是否冗余 (一个常见审稿人质疑: “为什么不直接简化为 actor-only TD3+BC?”), 我们把 β_2 设为 0、其余配置保持 winner 不变, 在两个 dataset 上 cross-validate。结果汇总于表 4。

Mean success 表面变化小, 但 Q 估计显著漂移. 两个 dataset 上移除 β_2 仅造成 -1.8 pp 至 -2.4 pp 的 mean success 下降, 看似 β_2 可有可无。但 **mean_target_q** 在两个 dataset 上分别漂移 **+98%** 与 **+46%** ($\hat{Q}$ 朝更不保守方向移动 $+7 \sim +8$ 个绝对单位)。两个 dataset 上 baseline $\hat{Q}$ 的符号原本相反 (crosscomp -8.25 偏悲观、worldcomp $+15.22$ 偏乐观), 移除 β_2 后都朝更不保守方向漂——这一漂移方向的 dataset-invariance 是 critic penalty 通过 target-Q bootstrap 抑制 Q 高估的直接证据。




图 1: seed-level success rate 分布 (worldcomp-1000, test=100 episodes)。横轴为 5 个 random seeds (42–46)，纵轴为成功率。三种协议：(i) TD3+BC privileged-critic ($\alpha = 0.1$, 灰色三角)；(ii) ReBRAC-Q deployable-only (蓝色圆点)；(iii) ReBRAC-Q privileged-critic (红色方块)。同一 seed 之间用细虚线连接，便于读出“deployable→privileged”在 seed 内部的位移。关键观察：seed 44 在 ReBRAC-Q deployable-only 下显著低于其他 seed (0.78 vs 0.93–0.99)，切换到 privileged-critic 后被救回到 0.90 (+12pp)；其他 seed 的“deployable→privileged”位移均在 $\pm 3\text{pp}$ 内，方向并不一致——privileged-critic 在 ReBRAC-Q 上的 mean 抬升完全由 seed 44 这一个 outlier 提供。

Outlier seed 44 在 crosscomp 上崩塌 17pp. 表 4 隐去了 per-seed 分布。事实上，crosscomp-1000 上 seed 44 在 $\beta_2 = 2$ 下取得 0.870， $\beta_2 = 0$ 下崩到 0.700 (−17pp)；其余 4 个 seed 的变化幅度均在 $\pm 3\text{pp}$ 以内。这与 Finding 2 中 seed 44 在 worldcomp 上“缺乏 privileged 信号即崩塌”的现象形成跨 (dataset, β_2) 的双向闭环：在两类 critic 稳定信号 (privileged hull-integral / critic-side BC penalty) 任一缺失下，seed 44 都会崩塌；任一存在则可救回。这有力反驳“seed 44 是统计噪声”的零假设。

2.2.4 Finding 4: critic LayerNorm 与 dual penalty 是两个独立必要组件

Tarasov et al. [2023] 在原 ReBRAC paper 中反复强调 critic LayerNorm 比 dual penalty 更关键。一个自然的审稿人质疑是：“ReBRAC-Q 的提升其实主要来自 LayerNorm，dual penalty 是 cosmetic”。表 5 用三向对比直接拆分这两个 component 的独立贡献。

表 4: β_2 ablation (critic-side BC penalty)。两个 dataset 上同时报告 mean success rate 与 mean target Q value。 $\hat{Q}$ 漂移以 percentage 形式给出 (相对 $\beta_2 = 2$ baseline)。

Dataset	Config	Success	$\hat{Q}_{\text{target}}$
cross-1000	$\beta_2 = 2$ (winner)	0.902 ± 0.024	−8.25
cross-1000	$\beta_2 = 0$	0.878 ± 0.101	−0.13 +8.12
world-1000	$\beta_2 = 2$ (winner)	0.928 ± 0.086	+15.22
world-1000	$\beta_2 = 0$ (2 seeds, probe)	0.910 ± 0.020	+22.30 +7.08

表 5: $\text{LN} \times \beta_2$ 三向消融 (crosscomp-1000, test=100)。

LN-off 在 2 seeds 上取得 −16.2pp 退化，远超 $\beta_2 = 0$ 的 −2.4pp。两类退化的 $\hat{Q}$ 漂移方向相反： $\beta_2 = 0$ 让 $\hat{Q}$ 朝过度乐观 (+8.12)；LN-off 让 $\hat{Q}$ 朝更负 (−3.84) 并伴随 std blow-up。

Config	n_{seed}	Success	Δ Mean	$\hat{Q}_{\text{target}}$
LN=on, $\beta_2 = 2$ (winner)	5	0.902 ± 0.024	—	−8.25
LN=on, $\beta_2 = 0$	5	0.878 ± 0.101	−2.4 pp	−0.13
LN=off, $\beta_2 = 2$	2	0.740 ± 0.255	−16.2 pp	−12.09

LN-off 退化幅度是 $\beta_2=0$ 的 6.7 $\times$. LN-off 让 mean success 退化 −16.2pp，远大于 $\beta_2 = 0$ 的 −2.4pp。同时跨 seed std 从 0.024 爆炸到 0.255 (约 11 $\times$ 放大)，其中 seed 42 单点从 0.92 崩到 0.56 (−36pp 单点崩溃)——LN-on 同 seed 在 $\beta_2 = 0$ 下仍是 0.92，说明“LN-off 触发的训练失稳模式”与“ $\beta_2 = 0$ 触发的 Q 高估模式”是两类独立失稳。

$\hat{Q}$ 漂移方向相反. $\beta_2 = 0$ 把 $\hat{Q}$ 朝更乐观方向推 (−8.25 $\rightarrow$ −0.13, +8.12)；LN-off 反而把 $\hat{Q}$ 朝更负方向推 (−8.25 $\rightarrow$ −12.09, −3.84) 并伴随 std blow-up。两类退化的 $\hat{Q}$ 漂移方向不同，因此它们不是同一现象的不同表述：dual penalty 抑制 actor OOD extrapolation 触发的 Q 高估；critic LayerNorm 抑制 critic 内部表征的局部爆炸。两者是两个独立必要组件，不可互相替代。

注：LN-off 的 $n = 2$ 仅支撑“LN 是必要组件”的存在性 claim；本文不就“LN 比 dual penalty 重要”做对比 claim (见 §??)。




图 2: β_2 ablation 下的 $\hat{Q}_{\text{target}}$ 漂移方向 (cross-dataset 一致性)。横轴为四个配置 (crosscomp-1000 $\beta_2 \in \{2, 0\}$ 、worldcomp-1000 $\beta_2 \in \{2, 0\}$)，纵轴为 mean target Q value。黑色箭头连接同 dataset 下 $\beta_2 = 2$ 与 $\beta_2 = 0$ 的 Q 值，箭头指向 $\beta_2 = 0$ 端。关键观察：两个 dataset 的 baseline $\hat{Q}$ 符号相反 (crosscomp -8.25 vs worldcomp $+15.22$)，但移除 β_2 后两者都朝“更不保守”方向漂 $+7 \sim +8$ 个绝对单位——critic penalty 抑制 Q 高估的机制是 dataset-invariant 的，不依赖具体 reward / Q 量级。

2.3 消融与机制 probe

本节把 §2.2 中的三个 finding 升级为机制论证：(i) β_2 ablation 的 cross-dataset $\hat{Q}$ -drift 一致性 (§2.3.1)；(ii) LayerNorm 与 dual penalty 是“两个相反方向的稳定机制” (§2.3.2)；(iii) privileged-critic 在 ReBRAC-Q 上仅做 outlier seed 救援，不做 mean 抬升 (§2.3.3)。

2.3.1 β_2 ablation: 跨 dataset 的 $\hat{Q}$ 高估抑制证据

我们把 §2.2.3 的 4 个 (dataset, β_2) 单元在图 2 中以条形对比可视化。两个 dataset 的 baseline $\hat{Q}$ 符号原本相反 (crosscomp 偏悲观、worldcomp 偏乐观)，但移除 β_2 后 $\hat{Q}$ 都朝更不保守方向漂 $+7 \sim +8$ 个绝对单位 (相对幅度 $+46\%$ 与 $+98\%$)。这一漂移方向的 dataset-invariance 是机制层面的硬证据：critic penalty 不是某个 dataset 上的偶然 cosmetic，而是通过 target-Q bootstrap 链路对 Q 估计施加的系统性正则化。

Outlier seed 鲁棒性。 seed 44 在 $\beta_2 = 0$ 下 crosscomp 取得 0.700 (vs $\beta_2 = 2$ 的 0.870)，单点崩塌 -17pp ；其余 4 seed 的下降均 $\leq 3\text{pp}$ 。结合 §2.2.2 中 seed 44 在 worldcomp 上的 dep $\rightarrow$ priv 救援 ($+12\text{pp}$)，这构成“seed 44 在两类 critic 稳定信号缺失下都崩、任

表 6: ReBRAC-Q (worldcomp-1000) deployable vs privileged-critic per-seed 分布。最后一行报告 5-seed mean / std。关键观察：除 seed 44 外，“deployable $\rightarrow$ privileged”位移均在 $\pm 3\text{pp}$ 内，方向不一致——privileged-critic 在 ReBRAC-Q 上的 $+0.6\text{pp}$ mean 提升完全由 seed 44 一个点提供。

Seed	Deployable	Privileged-critic	Δ
42	0.990	0.960	-0.030
43	0.930	0.920	-0.010
44	0.780	0.900	$+0.120$
45	0.980	0.930	-0.050
46	0.960	0.960	0.000
Mean $\pm$ Std	0.928 ± 0.086	0.934 ± 0.026	$+0.6 \text{ pp}$

一存在都可救回”的双向闭环。

2.3.2 LayerNorm ablation: 与 dual penalty 互补的稳定机制

§2.2.4 已经报告 LN-off 让 mean success 退化 -16.2pp 。本节进一步说明：LN-off 与 $\beta_2 = 0$ 的 $\hat{Q}$ 漂移方向相反 (前者朝更负 $+$ std blow-up，后者朝更正 $+$ mean 微跌)，表明两者控制不同的 failure mode。表 5 已整合在主文，本节只补一个观察：

LN-off 的 std blow-up ($0.024 \rightarrow 0.255$, 约 $11\times$) 说明 LayerNorm 主要稳定的是 seed-to-seed 的 RNG 路径方差，即不同 seed 进入不同 critic 内部表征状态的可能性。Dual penalty 主要稳定的是 policy 在 OOD 区域的 Q 估计，即 actor 偏离支持集时 Q 的外推幅度。这两类稳定性目标在数学上不重合，因此实证上它们的 $\hat{Q}$ 漂移方向相反。

2.3.3 Privileged-critic ablation: 仅救援 outlier seed, 不抬 mean

§2.2.2 已经报告 privileged-critic 在 ReBRAC-Q 上仅贡献 $+0.6\text{pp}$ mean，但救回 seed 44 $+12\text{pp}$ 。表 6 把 5 seeds $\times$ 2 protocols 的 per-seed success rate 完整列出。

这一结果与 TD3+BC 的 privileged-critic 行为形成对照：TD3+BC 上 privileged-critic 把 5-seed mean 抬升 $+6.4\text{pp}$ ($0.858 \rightarrow 0.922$)，是 mean-level 的整体提升而非仅 outlier 救援；ReBRAC-Q 上 privileged-critic 只抬 outlier seed 44，是“actor BC penalty 已经把 mean 抬

到上界、privileged 通道仅作 critic 信息冗余”的退化使用。这一现象在 §?? 中作为“actor-side 而非 critic-side 主导 deployable→teacher gap closure”的核心论据。

参考文献

Anonymous Authors. TD3+BC Phase 0c Cross-dataset Report (Internal). Internal technical report; reproducibility artifacts shipped with code release., 2026. Placeholder citation; replace with public-facing reference upon submission.

Scott Fujimoto and Shixiang Shane Gu. A minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

Denis Tarasov, Vladislav Kurenkov, Alexander Nikulin, and Sergey Kolesnikov. Revisiting the minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.