

第五章 局部感知下水下航行器运动规划的强化学习方法

5.1 引言

鱼类在河流中游动、鸟类在大气中飞行时，周围介质往往并非静止均匀。障碍物尾流、涡街、剪切层和热上升气流都会改变运动体相对于环境的受力与能耗。在工程控制中，这类非定常流动通常被视为外界扰动；生物运动研究则表明，局部感知与姿态调节也可能使运动体从环境流动中获得推进或节能条件。以鱼类为例，部分种类能在障碍物诱发的涡街中通过特定身体摆动维持位置，借周期性涡结构降低游动代谢消耗。支撑这类行为的并非对整个流场的完整测量，而是有限的局部感知；就鱼类而言，这一感知来自沿体表空间分布的侧线阵列，而非任何单一测点 [Liao, 2022, Coombs et al., 2020]。鸟类对热上升气流的利用也说明，运动体可以在局部感知和运动调节的共同作用下利用环境流动 [Flato et al., 2024]。

自主水下航行器（autonomous underwater vehicle, AUV）在尾流等结构化流场中执行运动规划时，面对的是相似但更受工程条件限制的问题。AUV 无法完整测量环境流场，只能依赖板载传感给出的局部流速或等效流速估计；这种信息不同于鱼类侧线的空间阵列，也不同于可直接输入学习系统的全场流场。由此引出本章的核心问题：在仅有单点局部感知的约束下，强化学习在何种条件下仍能形成可部署的运动规划策略？

这一约束在两种学习情形下含义不同。航行器若能与环境在线交互、反复试错，问题在于它能否仅凭单点感知学会运动规划，以及性能受何种因素制约。若在线交互不可行，策略只能从既有控制器采集的数据中离线学习 [Levine et al., 2020]，且部署阶段无法访问训练期才有的特权信息（privileged information），例如只在训练中可得的动力学有效流速信息 [Pinto et al., 2018]，问题便转为策略所能达到的性能上限。后一情形更贴近部署现实：受安全与成本约束的平台往往无法进行大量在线试错，只能复用既有数据，因而构成本章的重心；前一情形则用以考察任务在在线交互下的可学习性，并为离线结果提供解释基准。

这一问题在数据、传感与边界几个层面引出彼此关联的判别。就数据而言，离线学习对数据质量的依赖是否必然严苛，抑或在简单可部署控制器采集的数据中也可能恢复有效策略；就传感而言，不同传感配置之间的性能差距是否必须依赖更丰富的空间感知来闭合，还是可由对单点信号的充分时序利用部分替代；而当环境难度越过某一阈值、策略仍只能使用单点观测时，训练阶段的特权观测或特权示范能否突破部分可观测性造成的上限，则划出这一可行性的边界。

这些判别均限于一个受控的仿真运动规划基准；其确切的适用范围，由本章的环境难度、传感配置与任务设定共同限定。本章不将它们外推为对一切流场或平台的普遍结论。

本章的贡献在于，将这一部署约束下的运动规划问题转化为一组可检验的判别问题：单点局部感知在何种条件下足以支持有效策略，离线数据中的行为目标何时能够被可靠利用，训练期特权信息和更强策略先验又在何种边界内改变可部署性能。为回答这些问题，本章在共同的部署约束下比较在线异策略的 Actor-Critic 方法 [Haarnoja et al., 2018]、行为约束的离线方法 [Fujimoto and Gu, 2021, Tarasov et al., 2023]、更具表达力的生成式策略 [Park et al., 2025]，以及非对称 Actor-Critic 框架下对特权信息的利用 [Pinto et al., 2018]。由此形成的认识不依赖单一算法的偶然表现，而指向该问题本身的性能水平、支配机制与适用边界，并以多随机种子的统计检验约束相关判断。

本章据此提出一条贯穿全章的待检验线索：在部署约束下，可部署性能的提升可能更多依赖于对已有信息与数据的有效利用，而不是简单依赖于为系统增添能力。单点观测的时序利用与模仿目标同数据质量的适配，表面上分属传感与离线学习两个层面，实质上都在固定部署接口下提高既有轨迹中可被策略提取的信息量。与之相对，更多空间传感器、向价值网络注入特权观测、采用更具表达力的策略先验，分别代表增加观测、增加训练期信息和增加策略容量。它们是否必要、在何种条件下有效，构成本章的核心检验对象。可行性的来源及其边界由这条线索贯穿，而不取决于任何单一算法。

全章余下各节循此线索展开。第 5.2 节梳理相关研究并界定本章定位，第 5.3 节给出各条线索共享的问题设定与评估协议，第 5.4 节将本章所用的强化学习方法统一纳入同一算法框架，明确各方法在行为约束、参照目标与训练—部署信息边界上的异同。第 5.5 节考察在线情形下的任务可学习性及信号时序利用问题。离线情形构成本章重心：第 5.6 节给出可部署离线基线，第 5.7 节检验单点局部感知下离线学习能否达到可部署性能，第 5.8 节讨论这一可行性的边界，第 5.9 节比较不同算法与数据条件下的表现，第 5.10 节综合讨论各条线索共同指向的机制。

5.2 研究背景与定位

生物对流场的利用可从两个互补的角度理解：对运动而言，流场既是可资借用的能量来源，也是可供感知的信息来源。就能量而言，鱼类能在涡街与障碍物尾流中降低单体游动的代谢消耗，也能在群体中借尾拍与同伴尾涡之间的相位匹配，减少集体游动的能耗 [Liao, 2022, Di Santo and Goerig, 2025, Li et al., 2020]；这些现象的共同点在于，高效运动来自身体运动与流动结构在时空上的耦合，而非单纯增大推力。就信息而言，支撑上述行为的鱼类侧线是一种沿体表空间分布的感受阵列，而非单点的速度计 [Coombs et al., 2020]；这一结构提示，传感在空间上的组织方式本身，可能决定借流行为的可行性。同一原则在更广的类群与尺度上亦有印证：鸟类借热上升气流实现长距离滑翔，浮游生物则响应湍流中的局部梯度完成输运 [Flato et al., 2024, Mousavi et al., 2024]。

强化学习把这些借流现象从生物观察转化为可建模、可学习的控制问题。奠基性的工作让智能微游泳体在解析流场中学习游动方向以避开不利流区，并借助涡结构提升集体游动的推进效率 [Colabrese et al., 2017, Verma et al., 2018]。其后研究的重心转向局部感知：固定速度的游泳体在给定目标相对信息与局部流速的条件下，可以在非定常涡流中学到接近全局最优的高效轨迹 [Gunnarson

et al., 2021];而在自我中心坐标系下,单一的局部流速往往不足以支撑可靠学习,尚须辅以局部的流场梯度。这一结论恰与鱼类侧线的空间阵列结构相呼应 [Jiao et al., 2025]。更贴近工程实现的具身研究让柔性鱼形机器人在涡街与圆柱尾流中学习稳健的导航与姿态控制 [Zhu et al., 2022, Feng et al., 2025];相关研究还表明,流场对称性等物理结构会影响所学策略 [Qiu et al., 2022],并对复杂、局部可观测流场中不同方法的表现作了系统评估 [Mecanna et al., 2025]。

上述借流强化学习的研究大多假设智能体能与环境在线交互,本章面对的却是只能复用固定数据的离线情形。离线强化学习研究如何仅从一批固定数据中学习策略,而不与环境继续交互 [Levine et al., 2020];其核心困难在于分布偏移:策略一旦在数据未覆盖的动作上高估价值,便会偏离数据支持的区域,又无从在线纠正。围绕这一困难,已有方法形成几类思路不同的约束方式。一类从策略入手,将学得策略约束在采集数据的行为分布附近:早期工作通过对候选动作的显式筛选实现这一约束 [Fujimoto et al., 2019],其后的极简方法表明,仅在标准 Actor-Critic 目标上叠加一项行为克隆正则即可达到相当的效果 [Fujimoto and Gu, 2021],进一步的工作则在策略与价值两侧同时施加这类正则 [Tarasov et al., 2023]。另一类从价值入手,不显式约束策略:一种做法对分布外动作的价值作保守估计,主动压低未见动作的估值 [Kumar et al., 2020];另一种则以隐式回归学习价值,在更新中根本不查询未见动作,从而回避对其外推 [Kostrikov et al., 2022]。还有一类改变策略本身的表示,以更具表达力的生成式策略刻画可行动作,并在价值引导下从固定数据中学习策略 [Park et al., 2025]。这些方式各有侧重,约束的强弱、表示的繁简之间并无先天的优劣之分;在本章所关心的固定数据与部署受限传感条件下,关键问题转为这些约束与表示方式能否在不同数据质量下稳定转化为可部署策略的性能收益。

本章涉及的另一条脉络,处理训练与部署之间的信息不对称。当航行器只能获得部分可观测的局部信息时,一种常见做法是在训练阶段利用部署时无法获得的额外观测,即特权信息 (privileged information)。这一概念最初见于监督学习 [Vapnik and Vashist, 2009],在机器人学中则发展为师生范式:先用可访问特权信息的教师策略求解任务,再将其行为蒸馏到只依赖部署传感的学生策略 [Chen et al., 2020]。一种无需显式蒸馏的替代是非对称 Actor-Critic:训练期的价值网络接收特权观测以稳定学习,而策略本身始终只依赖部署阶段可得的输入 [Pinto et al., 2018]。这些做法的共同前提是特权信息确有助益、值得在训练期专门加以利用;至于在仅有单点局部感知的部署约束下,不借助任何特权信息时,可部署策略能否接近同类特权训练协议的性能,则尚少被直接追问。

将这几条脉络并置,便显出一处共同的空白。借流强化学习的研究大多依赖多于单点的流场观测,或允许智能体在线反复试错;离线强化学习的方法多在标准基准上验证,鲜少触及单点局部可观测这一物理传感约束;利用特权信息的工作则大多预设训练期的特权确有助益,并设法加以利用。若只有局部感知约束,在线交互仍可能通过试错补偿观测不足;若只有离线学习约束,标准基准又通常不要求策略从物理上受限的单点流速中恢复环境结构;若允许训练期特权信息,价值学习或策略蒸馏还可绕开一部分部署传感不足。三者同时成立时,问题才转化为一个更严格的判别:固定数据中是否已经包含足够信息,使只依赖单点部署观测的策略能够恢复可用的运动规划规律。

这一情形是受尺寸、功耗、成本与安全约束平台的一类典型处境,却至今缺乏系统刻画。它也不是对生物侧线结构的直接仿制;本章关心的是,在无法部署空间分布式流场阵列时,时间上的观测组织和离线数据中的行为目标能否补偿空间信息的缺失。本章即定位于这一交叉处,在共同的部

署约束与多随机种子的统计检验下，刻画局部感知约束下可行性的来源及其边界，并分析离线学习内部哪些因素实际支配算法表现。

5.3 问题设定与评估协议

本章三条线索——在线可学性、离线主线与算法对比——共享同一套任务、环境与部署接口。本节固定这一设定，并明确贯穿全章的四条对照轴：奖励目标、流动工况、传感配置与数据采集器。这一设定同时给出中心命题两侧的具体所指：策略在部署时实际掌握的信息，仅是 AUV 单点处的局部流速估计；可供离线学习复用的数据，是既有控制器采集的轨迹；而为系统增添能力的若干途径中，有两条可在本节的环境与接口层面精确定义，即增设空间探针与向价值网络注入特权观测；第三条途径，采用更具表达力的策略先验，属算法层面，留待方法节界定。全章结果表格中的奖励、工况与传感维度均以本节为基准。

5.3.1 任务与动力学

本章考虑一类水下自主航行器在卡门涡街（Kármán vortex street）尾流场中执行点到点运动规划的任务。航行器为 REMUS-100 类圆柱形载体（长 $L = 1.6$ m，直径 $d = 0.19$ m，排水质量 $m \approx 32$ kg），其动力学采用 Fossen 框架下完整的六自由度非线性方程组 [Fossen, 2011]，含附加质量、科氏力、横流阻力、桨叶推力与舵面升力，以四阶 Runge-Kutta 积分器在物理步长 $\Delta t_{\text{sim}} = 0.1$ s 上推进；每个决策步含 5 个物理子步，对应控制周期 $\Delta t_{\text{ctrl}} = 0.5$ s。深度由级联 PID 内环维持，使六自由度动力学在水平面退化为有效的三自由度平面运动 $[u, v, r, x_N, y_E, \psi]$ 。

尾流场由二维双弛豫时间格子玻尔兹曼方法离线生成，圆柱直径 $D = 12$ m，输出空间分辨率 $\Delta x = 0.6$ m，记录时长约 360 s（覆盖约九至十个涡旋脱落周期），每回合起始相位在记录区间内均匀随机采样以避免相位过拟合。本章在两个流动工况上考察策略。亚临界工况取来流 $U_\infty = 1.0$ m/s、雷诺数 $\text{Re} = 150$ ，处于严格的二维层流卡门涡街区间，是全章的主工况；临界工况取 $U_\infty = 1.5$ m/s、 $\text{Re} = 250$ ，涡旋更强、脱落更快，专用于刻画策略的失效边界。需说明的是，真实绕流在 $\text{Re} \approx 190$ 处发生三维失稳， $\text{Re} = 250$ 仍采用二维模型是一处明确的建模简化：它略微高估涡旋强度与斯特劳哈尔数，但不改变卡门涡街的定性时空结构。

任务几何以垂直来流方向（ $\pm 20^\circ$ 内随机）的横流穿越为主，目标对水速度上限 $V_{\text{max}} = 1.5$ m/s。两个工况下的速度比 $\lambda = U_\infty/V_{\text{max}}$ 分别为 0.67 与 1.0。当 $\lambda = 1.0$ 时，航行器在自由来流中可用于形成稳定对地位移的速度余量显著收缩，单纯按来流作直线补偿难以保证横流穿越任务中的净位移，因而需要利用尾流的非均匀结构——低速走廊、瞬态反向流与交变横向分量——获得可行运动。每回合起终点距离在 $[40, 90]$ m 内均匀采样，质心进入目标 4 m 半径内判成功，超出流场边界、动力学违规或超时（240 s）判失败。

表 5.1: 本章的三种传感配置。三者均对应 REMUS-100 平台上物理可实现的传感器； s_0 是全章策略网络共享的可部署主轴， s_1 与 s_2 仅作参考上界。单步观测维度为 8（本体 5 + 目标 3）+ $2n_p$ （ n_p 为探针数），到达导向奖励另加 2 个回合级上下文通道（见正文）。

布局	探针位置（体轴，m）	物理对应传感器	角色 / 感知类型
s_0	(0, 0)	DVL 1200 kHz 水追踪	可部署主轴；单点瞬时流速
s_1	(0, 0), (4.5, 0)	+ 2 MHz 短程 ADCP	参照上界；短程预警（ ~ 3 步）
s_2	(0, 0), (5, 0), (8, ± 4)	+ 1 MHz 长程 ADCP	参照上界；长程预警（ ~ 7 步）+ 侧向梯度

5.3.2 可部署观测与传感谱系

策略在每个决策步接收的可部署观测 $\mathbf{o}_t$ 由本体状态、目标信息与局部流速三部分拼接而成。本体五维为体轴线速度与偏航率 (u, v, r) 以及以 $(\cos \psi, \sin \psi)$ 编码的艏向（三角编码避免 $\pm\pi$ 跳变）；目标三维为目标在体坐标系下的相对位置 $(\Delta x_b, \Delta y_b)$ 与距离 d ，各量按固定尺度归一化，体坐标系表示使观测对全局朝向具有不变性。流速部分由探针布局决定：每个探针给出其所在位置体坐标系下的单点流速 (u_c, v_c) 。

本章涉及三种探针布局，均对应 REMUS-100 平台上物理可实现的传感配置（表 5.1）。 s_0 仅在机体质心 (0, 0) 设单一探针，对应平台标配的多普勒测速仪（DVL, 1200 kHz）水追踪模式所能给出的最弱流场感知——它只测得当前位置的瞬时流速，是单点流速测量的下界。这一布局是本章策略网络（actor）在三条线索中共享的部署主轴，也正是中心命题中策略可资利用的已有信息的物理载体。 s_1 在 s_0 之外增设一处前向探针 (4.5, 0)，对应一台 2 MHz 短程 ADCP，提供约三个控制步的轴向预警； s_2 进一步增设近端与两侧探针 (5, 0)、(8, ± 4)，对应 1 MHz 长程 ADCP，兼具约七步的轴向预警与侧向流速梯度感知。 s_1 与 s_2 在本章中仅作物理可对应的参照上界，用以界定 s_0 与更丰富空间感知之间的差距；本节不预设额外空间感知对可部署性能的必要性。

观测在送入策略前外接 $k = 4$ 步历史堆叠，以时间维度补偿单点感知缺失的空间信息。本章奖励设定在观测构成上仅有一处差异：到达导向奖励额外附带两个回合级上下文通道（已耗时间占比与归一化初始距离），历史效率导向奖励则无；这一差异来自到达导向奖励对时间语义与初始距离尺度的显式编码。因此 s_0 单步观测在历史效率导向奖励下为 10 维、在到达导向奖励下为 12 维，经 $k = 4$ 历史堆叠后分别为 40 维与 48 维；各结果表中的观测维度均以此为准。两类奖励在复现索引中的标识分别为 `efficiency_v2` 与 `arrival_v2`。

5.3.3 特权观测（仅价值网络）

为支持非对称 Actor-Critic [Pinto et al., 2018] 协议下的对照，环境另给出一路特权观测 $\mathbf{o}_t^{\text{priv}} \in \mathbb{R}^2$ 。它是 §5.1 中抽象引入的特权信息在本任务中的具体所指，即体坐标系下的沿机体采样等效来流 $(u_{\text{eq}}, v_{\text{eq}})$ 。这里的等效来流由沿 AUV 机体纵轴若干代表点采样平均得到，而非全场流场输入；

其数值由沿机体纵轴 $N = 5$ 个等距采样点的世界系流速等权平均、再投影至体坐标系给出：

$$\mathbf{o}_t^{\text{priv}} = (u_{\text{eq}}, v_{\text{eq}}) = \frac{1}{N} \sum_{i=1}^N R_{wb}(\psi) \mathbf{u}_{\text{world}}(\mathbf{p}^{(0)} + \xi_i L \hat{\mathbf{e}}_{\text{body}}), \quad \xi_i \in \{-0.4, -0.2, 0, 0.2, 0.4\}. \quad (5.1)$$

其中 $R_{wb}(\psi)$ 为世界系到体坐标系的旋转矩阵。该量等价于求解六自由度方程时实际作用于载体的有效来流，因而是物理含义明确的动力学有效输入，而非与动力学无关的任意隐藏变量；它在训练期可得、部署期不可得，恰是特权信息的定义性特征。与之相对，可部署观测中的单点流速只是探针所在位置的瞬时采样，并不等于驱动六自由度动力学的等效来流；二者之间的这一系统性信息落差，正是后续各方法比较所围绕的核心信息边界。

据此区分两种训练协议。可部署协议下，策略网络与价值网络 (critic) 都只读 $\mathbf{o}_t$ ，与本章定义的 REMUS-100 可部署传感接口一致；特权协议下，价值网络额外读取 $\mathbf{o}_t^{\text{priv}}$ ，而策略网络始终只读 $\mathbf{o}_t$ 。评估与部署阶段价值网络已被弃用， $\mathbf{o}_t^{\text{priv}}$ 不出现在执行回路中，故两种协议训练所得策略在部署时的传感依赖完全一致。图 5.1 示意了任务几何与两种协议下两个网络的传感边界。这一对照正是本章检验特权信息是否必需的实验杠杆：若可部署协议达到与特权协议相近的性能，则训练期额外提供的等效流速信息对部署性能并非必需。

5.3.4 动作、奖励与终止

航行器的动作为二维连续向量 $\mathbf{a}_t = (a_\psi, a_n) \in [-1, 1]^2$ 。在绝对航向模式下， a_ψ 映射为期望偏航角参考 $\psi_{\text{ref}} = a_\psi \cdot \pi$ ，由内层 PD 控制器跟踪； a_n 映射为归一化的螺旋桨转速指令。这两个分量分别支配航向选择与推进强度，构成策略借流机动的全部操纵自由度。

本章正式采用到达导向奖励作为任务成功率分析的主奖励设定。为说明其设计必要性，先回顾历史效率导向奖励，即离线主线早期所采用的奖励设定。该奖励以时间惩罚和目标距离进度整形为主体，并叠加轻量软安全代价与终止奖励；它适合在早期行为约束离线方法之间保持同口径比较，但在较难任务中可能产生目标错配：当策略难以到达目标时，持续累积的时间惩罚可能使提前出界获得比长时间接近目标更高的回报。

历史效率导向奖励由四项叠加构成，即每步时间惩罚、基于目标距离差的进度整形、轻量软安全惩罚以及终止奖励：

$$r_t = \underbrace{-c \Delta t_{\text{ctrl}}}_{\text{时间惩罚}} + \underbrace{k_p (d_{t-1} - d_t)}_{\text{进度整形}} - \underbrace{k_s c_t^{\text{safety}}}_{\text{软安全惩罚}} + r_{\text{term}}, \quad c = 2.0 \text{ s}^{-1}, \quad k_p = 1.0, \quad k_s = 0.25, \quad (5.2)$$

终止奖励 r_{term} 为到达目标的 +100 或失败的 -20，超界、动力学违规与超时均判失败； c_t^{safety} 为边界、姿态、速度与角速度风险的统一软代价。尽管该软安全项已对贴近边界的行为给出惩罚，其权重相对每步时间惩罚与终止项较弱。在较难任务中，这一奖励结构可能诱发一种退化模式：当目标在当前策略下难以到达时，持续累积的每步时间惩罚使提前出界成为回报更优的选择，失败惩罚 -20 与轻量安全项不足以抵消长时间漂行累积的时间代价，策略遂可能贴边滑行并尽早触发出界终止，使回合回报与任务成功率之间出现错配。这一沿边界提前失败的回报偏置暴露出历史效率导向奖励与任务主指标的错配，促成了向到达导向奖励的迁移。

基于这一失配，在线可学习性、泛化边界考察与算法比较统一采用到达导向奖励。该奖励不再把“更快结束”作为隐含优化方向，而是显式区分到达、超时与硬失败，并通过早失败惩罚抑制快速出界。每步奖励给出归一化的进度整形、微弱的时间代价与软安全惩罚：

$$r_t^{\text{step}} = w_p \frac{d_{t-1} - d_t}{d_0} - w_\tau \frac{\Delta t_{\text{ctrl}}}{T_{\text{max}}} - w_s c_t^{\text{safety}}, \quad (5.3)$$

回合终止时按语义附加终止项

$$r^{\text{term}} = \begin{cases} + R_{\text{succ}}, & \text{到达目标,} \\ - R_{\text{to}} - R_d \rho, & \text{超时,} \\ - R_{\text{fail}} - R_{\text{early}} (1 - \eta) - R_d \rho, & \text{硬失败,} \end{cases} \quad (5.4)$$

其中 $d_0 = \max(d_{\text{init}}, 10 \text{ m})$ 为带下界保护的初始目标距离， $\eta = \text{clip}(t/T_{\text{max}}, 0, 1)$ 为已耗时间占比， $\rho = \text{clip}(d_t/d_0, 0, 2)$ 为终止距离比；本章任务的起终点距离为 40–90 m，故该下界保护在正式评估分布内不激活。权重取 $w_p = 50$ 、 $w_\tau = 5$ 、 $w_s = 2$ ，终止系数 $R_{\text{succ}} = R_{\text{fail}} = R_{\text{early}} = 100$ 、 $R_{\text{to}} = R_d = 50$ 。

两处设计共同抑制了上述提前失败偏置。硬失败的早失败惩罚 $R_{\text{early}}(1 - \eta)$ 随已耗时间递减，使越早出界惩罚越重；该奖励设计满足的核心约束是，成功优于超时、超时优于硬失败，尤其快速出界不再优于接近目标的超时回合。同时，归一化的进度与时间项把每步信号压到低于终止项的量级，使任务语义主要由到达、超时与硬失败三类终止项表达，而不再由累积步惩罚主导。代价是奖励不再是纯势函数整形：到达、超时与硬失败的非势函数终止项直接编码任务语义，这一取舍意在换取与主指标对齐的可学习信号。两个回合级量（已耗时间占比 η 与按固定距离尺度归一化的初始目标距离）须进入观测，否则同一转移会因隐藏的已耗时间或初始距离获得不同回报，破坏价值函数的马尔可夫性；这正是到达导向奖励观测较历史效率导向奖励多两维的原因 (§5.3.2)。历史效率导向奖励保留在离线主线中，仅用于与既有实验结果保持同口径可比；其回报数值不与到达导向奖励下的回报作直接比较。跨设定讨论只限于任务成功率、部署约束、信息利用和失效边界等机制性结论。

5.3.5 数据集

离线数据由若干行为策略在上述环境中采集。目标直指参照与横流补偿参照是严格的 s_0 非学习控制器，前者直接朝目标航行并固定油门，后者依单点流速的体坐标系横向分量做反向偏航补偿；二者与待训练策略共享最弱传感协议。世界坐标系流速补偿参照作为理想化的可部署流速补偿基线，使用导航坐标系下的当前等效流速估计修正期望对地航迹；它不读取未来流场或全场候选走廊，但其信息口径强于仅由策略观测向量直接解码的严格单点观测控制器。全场走廊参照读取仿真器尾流场，为若干候选走廊打分并跟踪最优航迹，本身不可部署，仅用于生成高质量的参照数据。这里的全场走廊参照是行为数据采集器，不等同于 §5.3.3 中仅供价值网络读取的特权观测协议。

除上述规则型策略外，本章还引入由在线 SAC 策略检查点构成的采集器族。沿用离线强化学习基准构造数据的通行做法，从一条 SAC 训练轨迹的不同阶段截取检查点，得到质量递增的四档

表 5.2: 本章主要离线数据集及其在四条对照轴上的坐标。所有数据集共享 s_0 传感与 $k = 4$ 历史堆叠；观测维度由奖励设定决定（历史效率导向奖励为 40 维、到达导向奖励为 48 维）。FQL 的多模态与含噪变体、SAC 各档统计作为相应实验条件的一部分另行报告。

采集器	奖励设定	工况	回合数	用途
横流补偿参照	历史效率导向奖励	亚临界 Re150 / u10	1000 / 2000	历史效率导向离线数据
世界坐标系流速补偿参照	历史效率导向奖励	亚临界 Re150 / u10	1000	历史效率导向协议对照
横流补偿参照	到达导向奖励	亚临界 Re150 / u10	1000	亚临界到达任务数据
全场走廊参照	到达导向奖励	临界 Re250 / u15	1000	临界到达任务数据
全场走廊参照	到达导向奖励	亚临界 Re150 / u10	1000	高质量到达任务数据
SAC 检查点（四档）	到达导向奖励	亚临界 Re150 / u10	1000	SAC 检查点数据质量轴

采集器（随机、中等、中等偏专家、专家），其行为策略与 s_0 部署传感保持一致。这一数据源服务于算法对比线索，用以考察算法表现如何随数据质量变化，并提供规则型采集器覆盖不到的中等质量工况。

表 5.2 汇总本章主要离线数据集及其在四条对照轴——采集器、奖励设定、工况、传感——上的坐标，并标明各自用途。所有数据集统一采用 s_0 传感、 $k = 4$ 历史与横流穿越几何，每集 1000 回合（历史效率导向数据集另含一个 2000 回合预算）；差异集中在采集器（数据质量）、奖励目标与流动工况三轴。公共数据集的转移规模列于 §5.3.7，其余逐档统计随相应实验条件报告。

5.3.6 评估协议

所有方法在固定评估集（manifest）上以确定性策略评估。评估集是一组预先采样、各方法共用的起终点与流场相位配置，使不同算法、不同种子的成功率严格可比，其任务分布与对应数据采集时一致。主工况评估每种子 100 回合，较难工况与在线训练过程中的历史检查点评估每种子 30 回合；主指标为任务成功率，即质心进入目标半径内的回合占比。

成对协议的比较（如可部署协议与特权协议）以随机种子为主要推断单位：每个种子先在固定评估集上得到成功率，再比较种子级均值。两组独立的种子级成功率均值之差以 Welch 不等方差 t 检验判别 [Welch, 1947]，自由度按 Welch–Satterthwaite 公式计算。回合级配对自助法仅作为固定评估集下对配对任务实例的敏感性复核 [Efron and Tibshirani, 1993]，即在保持方法配对关系的前提下对评估任务实例重采样，报告均值差的百分位置信区间，用于检查结论是否依赖少数起终点或流场相位；它不替代种子级推断，也不把回合视为独立推断样本。当 t 检验不拒绝等均值且自助置信区间跨越零时，本章表述为未检测到统计显著差异；若进一步作出性能相近或等价判断，则同时要求种子级效应量落在相应结果节预先给出的实践容忍范围内。

对成功率为零的负面结果，单凭点估计不足以界定其上界。本章按 rule-of-three 给出此类零计数的 95% 置信上界约 $3/n$ [Jovanovic and Levy, 1997]，使“完全失败”这一结论本身带有量化的统计强度，与正面结果同台呈现而非降格为附带说明。随机种子取固定数量的一组，全章各线在其协议内保持一致；正文报告种子数量和每种子评估回合数，具体随机种子编号保留在复现实验配置与

表 5.3: 共享设定的复现索引。表中列出本节直接承担的公共数据与评估入口；FQL 多模态、含噪变体及 SAC 四档的逐档统计随相应实验条件报告。

用途	数据 / 评估入口	奖励与工况	观测	种子 / 回合
TD3+BC / ReBRAC: 历史效率导向离线主线	crosscomp_s0_h4_efficiency_v2_re150_u10cross_ep1000/2000	历史效率导向奖励, Re150 / u10	$s_0, h = 4, 40\text{-D}$	5 seeds; 100 eval ep
TD3+BC / ReBRAC: 可部署-特权协议对照	worldcomp_s0_h4_efficiency_v2_re150_u10cross_ep1000	历史效率导向奖励, Re150 / u10	$s_0, h = 4, 40\text{-D}$	5 seeds; 100 eval ep
亚临界到达任务数据	crosscomp_s0_h4_arrival_v2_re150_u10cross_ep1000	到达导向奖励, Re150 / u10	$s_0, h = 4, 48\text{-D}$	固定种子组
临界到达任务数据	privileged_s0_h4_arrival_v2_re250_u15cross_ep1000	到达导向奖励, Re250 / u15	$s_0, h = 4, 48\text{-D}$	固定种子组
主工况评估	single_u10_cross_tgt15	与训练数据一致	manifest 固定起终点与相位	100 ep / seed
较难工况评估	single_u15 系列	Re250 / u15	manifest 固定起终点与相位	30 ep / seed

结果记录中。

5.3.7 实施细节与可复现性

观测各通道的归一化常数为: 速度尺度 2.0 m/s (本体与流速通道共用)、偏航率尺度 1.0 rad/s、距离尺度 200 m。到达导向奖励的两个回合级上下文通道分别为已耗时间占比 $\eta \in [0, 1]$ 与按 200 m 归一化的初始目标距离。特权观测 $\mathbf{o}^{\text{priv}} = [u_{\text{eq}}, v_{\text{eq}}]$ 维度为 2、不随历史堆叠, 离线数据以 $\mathbf{o}^{\text{priv}}$ 与其后继 $\mathbf{o}'^{\text{priv}}$ 两列随转移一并记录, 以支持接收特权观测的价值网络协议。

公共数据集的规模如下: 横流补偿参照的 1000 / 2000 回合集分别约含 2.4×10^5 / 4.8×10^5 条转移, 世界坐标系流速补偿参照的 1000 回合集约 2.0×10^5 条。到达导向奖励下的基线采集器与 SAC 检查点采集器同样以 1000 回合为基本规模; SAC 四档采集器的逐档转移条数、行为质量与失败模式分布在算法对比分析中给出。

Welch-Satterthwaite 自由度由两组样本方差与样本量按标准公式计算; 配对自助法取 $B = 10^4$ 次回合级重采样给出百分位置信区间。主工况评估集为 **single_u10_cross_tgt15** (每种子 100 回合), 较难工况评估集为 **single_u15** 系列 (每种子 30 回合)。离线主线固定 5 个随机种子, 泛化边界与算法对比在各自协议内使用固定种子组; 具体随机种子编号不作为正文论证对象, 保留于复现实验配置。

5.4 强化学习方法与算法框架

§5.3 固定了贯穿全章的任务、观测、奖励与数据集协议; 本节在此基础上把本章所比较的学习方法纳入同一个强化学习框架。这些方法并非互不相关的算法, 而是同一部署约束下对信息的不同利用方式。它们共享策略网络与价值网络的基本分工, 共享离线数据或在线交互这两类信息来源, 也共享价值自举与行为约束等构件; 区别只在于以何种方式把策略约束在数据支持之内, 以及在训练阶段允许哪一方接触何种信息。把这些共同构件一次性定义清楚, 各方法的机制证据与实验协议便可在共同的算法语言下展开, 而不必反复重述算法基础。为此, 本节先统一符号与方法边界, 再依次给出在线最大熵方法、行为约束离线基线、双侧正则的离线主线方法、以及以更具表达力的生成式先验为参照目标的离线方法, 最后抽象出训练期与部署期的信息协议。

5.4.1 从部分可观测任务到异策略学习问题

§5.3.1 所述的航行器在尾流场中的运动规划，是一个部分可观测的连续控制问题。真实流场与航行器六自由度动力学的完整状态可记为 $\mathbf{s}_t$ ，但策略无法直接读取它；策略在每个决策步只能获得由观测算子 Ω 给出的可部署观测 $\mathbf{o}_t = \Omega(\mathbf{s}_t)$ ，并据此输出二维连续动作 $\mathbf{a}_t$ 。沿用部分可观测马尔可夫决策过程（partially observable Markov decision process, POMDP）的标准表述，学习目标是寻找一个策略网络（actor） π_θ ，使其在给定可部署观测下选择的动作能最大化折扣回报：

$$\mathbf{o}_t = \Omega(\mathbf{s}_t), \quad \mathbf{a}_t \sim \pi_\theta(\cdot | \mathbf{o}_t), \quad J(\pi_\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^T \gamma^t r_t \right], \quad (5.5)$$

其中 r_t 为 §5.3.4 给出的奖励， $\gamma \in (0, 1)$ 为折扣因子， T 为回合长度。在确定性策略的情形下， $\pi_\theta(\mathbf{o})$ 直接给出动作而非其分布；本节随方法不同分别采用随机与确定性两类策略网络，但学习目标统一为 (5.5)，并在 §5.3.6 的固定评估协议下以任务成功率作为最终度量。这一表述的关键之处在于观测与状态之间的信息落差：策略实际掌握的至多是探针处的局部流速采样，在可部署的 $\mathbf{s}_0$ 配置下更只是单点瞬时流速，而真正驱动动力学的是沿船体的等效来流。可部署观测与特权观测之间的这一差异，正是本章各方法比较所围绕的核心信息边界，其精确定义见 §5.3.2 与 §5.3.3。

策略据以学习的数据来源分为两类，对应在线与离线两种学习范式。在线强化学习允许策略在训练过程中与环境反复交互，把交互产生的转移存入经验回放缓冲区 $\mathcal{B}$ ，并以此持续评估与改进当前策略。离线强化学习则不进行任何在线交互，策略只能使用一个预先采集、训练期间固定不变的数据集

$$\mathcal{D} = \{ (\mathbf{o}_t, \mathbf{a}_t, r_t, \mathbf{o}_{t+1}, d_t) \}, \quad (5.6)$$

其中 d_t 为终止标志，数据由若干行为策略按 §5.3.5 的协议采集。两种范式共享同一套观测、动作与奖励定义，但离线范式带来一处本质困难：策略改进的方向由价值网络（critic）的估计引导，而价值网络只在数据覆盖到的状态-动作区域内可靠，一旦策略偏离数据支持去查询分布外动作（out-of-distribution action），价值估计便会外推并产生系统性高估，进而把策略推向数据从未验证的区域，形成自我强化的偏差 [Levine et al., 2020]。因此离线方法的共同任务，是在尽量改进策略的同时把它约束在数据支持之内；本节后续介绍的三种离线方法，差别正在于以何种形式施加这一约束。

5.4.2 在线异策略 Actor-Critic 与 SAC

本章所用的学习方法都属于异策略（off-policy）Actor-Critic 框架。该框架把学习分解为两个相互耦合的部分：策略网络负责在给定观测下产生动作，价值网络则估计动作价值函数 $Q(\mathbf{o}, \mathbf{a})$ ，即在该观测下执行该动作并此后遵循当前策略所能获得的期望折扣回报。异策略意味着用于更新的转移不必来自当前策略本身，既可以是回放缓冲区中由历史策略产生的交互，也可以是离线数据集中由行为策略采集的轨迹；这一性质使同一框架既能支撑在线学习，也能支撑从固定数据集的离线学习。价值网络通过自举（bootstrap）更新：以单步奖励加上对后继观测的价值估计构成回归目标 y ，

并令价值网络逼近该目标，

$$y = r + \gamma(1 - d) \min_{j=1,2} Q_{\bar{\phi}_j}(\mathbf{o}', \mathbf{a}'), \quad \mathcal{L}_Q = \sum_{j=1,2} \mathbb{E}[(Q_{\phi_j}(\mathbf{o}, \mathbf{a}) - y)^2]. \quad (5.7)$$

其中 $\bar{\phi}_j$ 为价值网络的目标网络参数，随主网络以系数 τ 作软更新。为抑制价值高估，框架采用两套价值网络并在目标中取二者较小值 (clipped double-Q)； $\mathbf{a}'$ 为后继观测下由策略选取的动作，其具体形式随方法而异，是区分各方法的首要接口。

后继动作 $\mathbf{a}'$ 的选取方式区分出两个分支。随机策略分支以一个随机策略网络刻画动作分布，并在自举目标中加入策略熵；确定性策略分支则使用确定性策略网络，并借助目标策略平滑与延迟策略更新来稳定训练——后继动作由目标策略的输出叠加一段经截断的高斯噪声给出，

$$\tilde{\mathbf{a}}' = \text{clip}(\pi_{\bar{\theta}}(\mathbf{o}') + \epsilon, -1, 1), \quad \epsilon \sim \text{clip}(\mathcal{N}(0, \sigma^2 I), -c, c), \quad (5.8)$$

其中 $\pi_{\bar{\theta}}$ 为目标策略网络， σ 与 c 分别为平滑噪声的标准差与截断幅度。双价值网络、目标网络、目标策略平滑与延迟策略更新，是 TD3 一系确定性方法用于减轻价值高估与训练震荡的共同基础设施 [Fujimoto et al., 2018]；本章的三种离线方法都建立在这一确定性分支之上，其差异在后续小节给出。

在线情形采用最大熵异策略方法 SAC [Haarnoja et al., 2018]。SAC 属随机策略分支，以一个经压缩高斯分布参数化的策略网络刻画动作分布，并在优化回报的同时最大化策略熵，从而在探索与利用之间取得平衡。其自举目标在 (5.7) 的基础上对后继动作的对数概率加以惩罚，策略改进则在价值与熵之间权衡，

$$\mathcal{L}_{\pi}^{\text{SAC}} = \mathbb{E}_{\mathbf{o} \sim \mathcal{B}, \mathbf{a} \sim \pi_{\theta}} [\alpha_{\text{ent}} \log \pi_{\theta}(\mathbf{a} | \mathbf{o}) - Q_{\phi}(\mathbf{o}, \mathbf{a})], \quad (5.9)$$

其中熵温度系数 α_{ent} 在训练中自动调节，以维持目标熵水平。在本章中，SAC 承担两个方法性角色：其一是在线情形下任务可学习性的参照，用以考察策略能否仅凭可部署观测在交互中习得有效的运动规划；其二是离线数据的一类来源，即由 SAC 训练轨迹不同阶段的检查点构成质量递增的采集器 (§5.3.5)。这两个角色都不要求 SAC 在部署性能上与离线方法竞争，它在本章中并非主线算法，而是为离线比较提供在线一侧的参照与数据。

5.4.3 行为约束离线 Actor-Critic: TD3+BC

在确定性分支上施加行为约束的最简形式是 TD3+BC [Fujimoto and Gu, 2021]。它在 TD3 的确定性策略梯度之上叠加一项行为克隆 (behavior cloning, BC) 惩罚，使策略在追求高价值动作的同时不至于偏离数据集中实际出现过的动作。其价值网络按 (5.7) 与 (5.8) 给出的确定性自举目标更新，不含任何附加惩罚项；行为约束只作用于策略改进一侧，

$$\mathcal{L}_{\pi}^{\text{TD3+BC}} = -\lambda_{\text{TD3+BC}} \mathbb{E}_{\mathbf{o} \sim \mathcal{D}} Q_{\phi}(\mathbf{o}, \pi_{\theta}(\mathbf{o})) + \mathbb{E}_{(\mathbf{o}, \mathbf{a}) \sim \mathcal{D}} \|\pi_{\theta}(\mathbf{o}) - \mathbf{a}\|^2, \quad \lambda_{\text{TD3+BC}} = \frac{\alpha_{\text{BC}}}{\mathbb{E} |Q_{\phi}(\mathbf{o}, \pi_{\theta}(\mathbf{o}))|}. \quad (5.10)$$

第一项推动策略选择价值更高的动作，第二项把策略输出拉向同一观测下的数据动作 $\mathbf{a}$ 。系数 $\lambda_{\text{TD3+BC}}$ 按批量内价值幅度的均值对价值项作归一化，使其量级与行为克隆项可比，从而单一

超参数 α_{BC} 即可在不同奖励尺度的数据集上一致地调节“改进”与“模仿”之间的权衡。这一设计把离线策略改进约束在数据支持附近，是异策略离线学习中行为约束的基准形式。

TD3+BC 给出了行为约束离线方法的最小实现，但它把数据支持的全部信息压缩在单一的原始动作模仿项上。这一项无法区分数据中行为质量、动作噪声与价值外推这几类不同来源的影响：当数据动作本身质量参差或带有噪声时，对原始动作的逐点模仿会把噪声一并学入策略；而仅靠策略一侧的约束，也不足以阻止价值网络在自举链路上对分布外的后继动作产生外推偏差。这些局限提示，更充分的离线方法需要在策略与价值两侧同时施加约束，或为模仿提供比原始数据动作更可靠的参照目标。本章后续两种离线方法分别沿这两个方向展开，而 TD3+BC 则作为它们的共同参照基线。

5.4.4 ReBRAC-Q: Q 归一化双正则 TD3+BC 变体

本章的离线主线方法记为 ReBRAC-Q，它是一个 Q 归一化的双侧正则 TD3+BC 变体。它沿用 TD3+BC 以批量价值幅度对策略改进项作归一化的做法（下称 Q 归一化），并在此基础上把行为约束从策略一侧扩展到策略与价值两侧：策略一侧仍以原始动作行为克隆把策略拉向数据动作，价值一侧则在自举目标中额外惩罚后继动作对数据支持的偏离。这一双侧正则的设计源自最小改动型的离线方法 ReBRAC [Tarasov et al., 2023]；本文方法与原始 ReBRAC 的主要差异，在于策略改进项是否采用 TD3+BC 风格的批量均值 $|Q|$ 归一化 [Fujimoto and Gu, 2021]——本文方法采用这一归一化，故以 ReBRAC-Q 命名，全章统一使用该名称指代本文的离线主线方法。

策略一侧的目标在 TD3+BC 的形式上把行为克隆项的强度显式参数化。记策略改进项的归一化系数为 λ_Q ，由批量内价值幅度的均值（取自当前策略动作处、并在该系数计算中切断梯度）给出，

$$\bar{Q} = \mathbb{E}_{\mathbf{o} \sim \mathcal{D}} |Q_\phi(\mathbf{o}, \pi_\theta(\mathbf{o}))|_{\text{detach}}, \quad \lambda_Q = \frac{1}{\max(\bar{Q}, \varepsilon)}, \quad (5.11)$$

策略目标则为归一化的价值改进项与原始动作行为克隆项之和，

$$\mathcal{L}_\pi^{\text{ReBRAC-Q}} = -\lambda_Q \mathbb{E}_{\mathbf{o} \sim \mathcal{D}} Q_\phi(\mathbf{o}, \pi_\theta(\mathbf{o})) + \beta_1 \mathbb{E}_{(\mathbf{o}, \mathbf{a}) \sim \mathcal{D}} \|\pi_\theta(\mathbf{o}) - \mathbf{a}\|^2. \quad (5.12)$$

系数 β_1 控制策略输出贴近数据动作的强度，是策略一侧行为约束强度的显式系数； λ_Q 只对价值项作尺度归一化（ ε 为防止除零的数值下界），并不改变奖励定义或任务目标。 β_1 与 TD3+BC 中的 α_{BC} 只有在本文这一 Q 归一化写法下才存在近似的换算关系，二者并非同一量纲下的同一系数；本节只给出系数含义，其取值与跨设定的对照留待相应结果节讨论。

价值一侧的正则项作用于自举目标。沿用 (5.8) 给出的经目标平滑的后继动作 $\tilde{\mathbf{a}}'$ ，ReBRAC-Q 在 (5.7) 的双价值网络目标基础上，对后继动作偏离数据支持的程度施加二次惩罚，

$$y^{\text{ReBRAC-Q}} = r + \gamma(1-d) \left[\min_{j=1,2} Q_{\phi_j}(\mathbf{o}', \tilde{\mathbf{a}}') - \beta_2 \|\tilde{\mathbf{a}}' - \mathbf{a}'_{\mathcal{D}}\|^2 \right], \quad (5.13)$$

其中 $\mathbf{a}'_{\mathcal{D}}$ 是同一条离线轨迹中与 $\mathbf{o}'$ 对应的下一步数据动作。该惩罚比较的是自举所用的后继动作 $\tilde{\mathbf{a}}'$ 与数据中实际记录的下一步动作 $\mathbf{a}'_{\mathcal{D}}$ 之间的偏离，因而衡量的是价值自举是否落在数据支持之内——当目标动作偏离数据动作越远，价值目标被压低得越多，从而抑制价值网络沿自举链路对分布

外动作的外推。系数 β_2 控制这一价值侧约束的强度。它与策略一侧的行为克隆项作用机理不同：策略侧的项约束的是部署时实际执行的策略输出，价值侧的项约束的则是训练中价值目标所依赖的后继动作；两者共同把策略与价值都锚定在数据分布附近，是 ReBRAC-Q 区别于单侧约束 TD3+BC 的核心增量。

ReBRAC-Q 还在价值网络中引入层归一化 (LayerNorm) 作为表征稳定性的基础设施。离线价值估计长期在固定数据集上自举，价值网络的内部表征容易随训练发散，进而放大上述外推偏差；在价值网络中加入层归一化可约束其内部激活的尺度，与上述双侧行为约束共同维持离线价值估计的稳定。层归一化既不是部署阶段的额外信息，也不是任何额外的传感能力，它与“特权信息是否必需”这一问题相互正交：它服务于价值估计在训练期的数值稳定，而不改变策略在部署时所依赖的观测。因此本章把层归一化视为离线价值学习的必要构件，而非可有可无的附加项。

5.4.5 FQL：流匹配行为建模与蒸馏策略

ReBRAC-Q 以原始数据动作作为模仿目标，这在数据动作可靠时是恰当的，但当行为分布呈多模态或带有噪声时，对原始动作的逐点模仿未必给出最好的参照。FQL [Park et al., 2025] 沿另一方向改造行为约束：它不直接以原始数据动作作为模仿目标，而是先用一个生成式模型刻画数据中的行为分布，再以该模型给出的参照动作引导策略。具体而言，FQL 把条件动作分布建模为从高斯噪声到数据动作的连续流（流匹配，flow-matching），并学习一个条件速度场 $v_\eta(\mathbf{x}_t, t | \mathbf{o})$ ；沿噪声到数据动作的线性插值路径，速度场的回归目标恰为数据动作与噪声之差，

$$\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{a}, \quad \mathbf{x}_0 \sim \mathcal{N}(0, I), \quad v^* = \mathbf{a} - \mathbf{x}_0, \quad \mathcal{L}_{\text{flow}} = \mathbb{E} \|v_\eta(\mathbf{x}_t, t | \mathbf{o}) - v^*\|^2, \quad (5.14)$$

其中 $t \in [0, 1]$ 为流时间， $\mathbf{x}_t$ 为该路径上的中间点。沿学得的速度场对噪声起点作积分，即可得到一个经去噪的参照动作，记为 $\mathbf{a}_{\text{FM}}(\mathbf{o})$ ，它代表在该观测下行为分布所支持的一个高似然动作。

部署阶段并不直接执行上述生成式模型的积分过程，而是执行一个一步确定性策略网络 μ_θ 。该策略网络通过蒸馏对齐到流匹配模型积分得到的参照动作 $\mathbf{a}_{\text{FM}}$ ，同时仍借助价值网络以归一化的价值改进项进行策略改进，

$$\mathbf{a}_{\text{FM}}(\mathbf{o}) = \text{Integrate}(v_\eta(\cdot, \cdot | \mathbf{o})), \quad \mathcal{L}_\pi^{\text{FQL}} = -\lambda_Q \mathbb{E} Q_\phi(\mathbf{o}, \mu_\theta(\mathbf{o})) + \alpha_{\text{FQL}} \mathbb{E} \|\mu_\theta(\mathbf{o}) - \mathbf{a}_{\text{FM}}(\mathbf{o})\|^2, \quad (5.15)$$

其价值网络按确定性自举目标更新，不含价值一侧的行为克隆惩罚；与 ReBRAC-Q 相同，其价值网络亦采用层归一化以稳定离线价值估计。FQL 与 ReBRAC-Q 在框架上高度一致：二者都属确定性策略分支，都以 Q 归一化的价值改进项驱动策略，都通过一项二次模仿项把策略约束在数据分布附近。二者的关键差异在于模仿项所指向的参照目标——ReBRAC-Q 指向原始数据动作 $\mathbf{a}$ ，FQL 指向由流匹配模型去噪生成的参照动作 $\mathbf{a}_{\text{FM}}$ 。参照目标来源上的这一差异，正是本章在算法与数据条件之间作交互分析时所依据的方法接口。

5.4.6 训练期特权信息与部署期策略接口

上述方法都在同一部署接口下学习，但在训练阶段允许价值网络接触的信息可以不同。§5.3.3 已把特权观测 $\mathbf{o}_t^{\text{priv}}$ 定义为训练期可得、部署期不可得的沿船体等效来流估计；据此，本章区分两种训练协议。在可部署协议下，策略网络与价值网络都只读取可部署观测 $\mathbf{o}_t$ ，与本章定义的可部署传感接口完全一致。在特权协议下，价值网络在训练中额外读取特权观测 $\mathbf{o}_t^{\text{priv}}$ ，而策略网络始终只读取 $\mathbf{o}_t$ ；这一非对称安排沿用非对称 Actor-Critic 的思路 [Pinto et al., 2018]，即让价值网络在训练期借助更完整的信息给出更准确的价值估计，同时保持策略本身可部署。同样的非对称安排亦可施加于在线 SAC：其价值网络在训练期可选地读取特权观测，构成在线情形下的特权消融对照。为使记号简洁，本节所列价值网络目标式（如 (5.7) 与 (5.13)）均按可部署协议写出，价值网络只读 $\mathbf{o}$ ；在特权协议下，相应价值网络及其目标网络改读 $Q_\phi(\mathbf{o}, \mathbf{a}, \mathbf{o}^{\text{priv}})$ 与 $Q_{\bar{\phi}_j}(\mathbf{o}', \cdot, \mathbf{o}'^{\text{priv}})$ ，其余形式不变。

两种协议的部署接口完全相同。评估与部署阶段只执行策略网络，价值网络在训练结束后即被弃用，特权观测 $\mathbf{o}_t^{\text{priv}}$ 不出现在执行回路中；因此无论训练时价值网络是否接触过特权观测，所得策略在部署时所依赖的传感完全一致，都只是单点局部流速。这一性质使两种协议构成一组干净的对照：在保持策略部署接口不变的前提下，特权协议相对可部署协议唯一改变的是训练期价值网络可用的信息量。借助这一对照，可以单独考察“在训练期把特权信息提供给价值网络”是否会改变所得可部署策略的性能。这里的特权观测是仅供价值网络读取的训练期信号，与 §5.3.5 中那种读取全场流场以采集高质量数据的行为采集器并非一回事：前者改变的是价值估计所用的信息，后者改变的是离线数据的来源与质量。

5.4.7 实施细节与可复现性

本章各方法共用一套符号与实现口径。状态、动作、奖励、终止与后继观测分别记为 $\mathbf{s}_t$ 、 $\mathbf{o}_t$ 、 $\mathbf{a}_t$ 、 r_t 、 d_t 与 $\mathbf{o}_{t+1}$ ，离线数据集记为 $\mathcal{D}$ 、在线回放缓冲区记为 $\mathcal{B}$ ，策略网络与价值网络分别记为 π_θ （确定性情形下亦记为 μ_θ ）与 Q_ϕ ，其目标网络参数记为 $\bar{\theta}$ 、 $\bar{\phi}_j$ ，折扣因子与软更新系数分别为 γ 与 τ 。后继观测下用于自举的动作记为 $\mathbf{a}'$ ，其经目标策略平滑的形式记为 $\bar{\mathbf{a}}'$ ，同一离线轨迹中与后继观测 $\mathbf{o}'$ 对应的下一步数据动作记为 $\mathbf{a}'_{\mathcal{D}}$ 。行为约束系数中， α_{BC} 为 TD3+BC 的单一行为克隆权重， β_1, β_2 分别为 ReBRAC-Q 策略一侧与价值一侧的行为约束权重， α_{FQL} 为 FQL 的蒸馏模仿权重， α_{ent} 为 SAC 的熵温度系数。各方法的二次模仿与支持惩罚项（含策略一侧的原始动作模仿与价值一侧的下一步支持惩罚）在实现上或按动作维求和、或按动作维取均值，二者相差一个与动作维数有关的常数因子，已并入相应的行为约束系数，不影响其作为强度调节量的含义。Q 归一化中的下界 ε 仅为数值稳定而设，不承担任何调节作用。确定性分支共用的目标策略平滑噪声、噪声截断幅度与延迟策略更新频率，作为 TD3 一系方法的共同实现口径，在各离线方法中保持一致；其中 TD3+BC 的策略改进项按其原始实现取单一价值网络的估计，而所有方法的自举目标以及双侧正则方法的策略改进项均取双价值网络的较小值。特权观测的维度与物理含义已在 §5.3.3 给定，本节不再重复其推导；离线数据集为支持特权协议，随每条转移一并记录特权观测及其后继 (§5.3.7)。各方法的具体超参数取值、数据集规模与统计结果，随相应结果节给出。

表 5.4: 本章强化学习方法框架总表。四种方法同属异策略 Actor-Critic 框架, 差异集中在策略形式、行为约束与训练期网络可用观测; “本章角色”列只标方法定位, 不含结果结论。层归一化是 ReBRAC-Q 价值网络的表征稳定性构件, 归入其行为约束/先验栏。

方法	训练范式	策略输出	行为约束 / 先验	策略网络观测	价值网络观测	本章方法角色
SAC	在线异策略	随机策略 (最大熵)	熵正则	可部署观测	可部署观测 (特权消融可选)	在线可学性参照与数据采集
TD3+BC	离线异策略	确定性策略	原始动作行为克隆	可部署观测	可部署或特权观测	离线基线
ReBRAC-Q	离线异策略	确定性策略	策略与价值双侧行为克隆 + Q 归一化 + LayerNorm	可部署观测	可部署或特权观测	离线主线
FQL	离线异策略	蒸馏确定性策略	流匹配参照动作	可部署观测	可部署观测	算法—数据条件交互对照

表 5.5: 本章方法的损失函数与信息协议汇总。各方法共用 (5.7) 的双价值网络自举与 (5.8) 的确定性目标平滑 (SAC 为其随机最大熵变体); ReBRAC-Q 在价值目标中额外含 β_2 的下一步支持惩罚。“特权信息可能出现处”指特权观测在该方法中可被读取的网络, 部署阶段一律不出现。

方法	策略目标	价值目标	模仿 / 参照对象	特权信息可能出现处
SAC	熵正则策略改进 (5.9)	软 Bellman 目标	无显式行为克隆项	价值网络 (在线特权消融, 可选)
TD3+BC	Q 归一化策略改进 + 原始动作行为克隆 (5.10)	TD3 自举目标 (5.7)	数据动作 $\mathbf{a}$	价值网络 (两协议均可)
ReBRAC-Q	Q 归一化策略改进 + β_1 原始动作行为克隆 (5.12)	含 β_2 下一步支持惩罚的 TD 目标 (5.13)	数据动作 $\mathbf{a}$ (策略侧)、 $\mathbf{a}'_D$ (价值侧)	价值网络 (两协议均可)
FQL	Q 归一化策略改进 + 蒸馏参照行为克隆 (5.15)	TD 式自举目标	流匹配参照动作 $\mathbf{a}_{FM}$	本章 FQL 线不依赖

表 5.4 汇总四种方法在训练范式、策略输出、行为约束、网络观测与本章角色上的坐标, 表 5.5 进一步给出各方法的策略目标、价值目标、模仿参照对象与特权信息可能出现的位置。两表统一了后续结果节所引用的符号与方法关系: 异策略 Actor-Critic 是四种方法的共同框架, SAC 与三种离线方法的区别在于随机与确定性策略以及在线与离线数据来源, 三种离线方法之间的区别则集中在行为约束的位置 (策略侧、价值侧)、参照目标的来源 (原始数据动作、流匹配参照动作) 与价值表征稳定性构件上。这些差异都不改变策略在部署时只读取单点局部观测这一共同接口, 因而后续各节对它们的比较, 是同一部署约束下可解释的比较, 而非互不相干的算法堆叠。

在上述统一框架下, 各方法的差异被归结为三类接口选择: 行为约束施加的位置、模仿所依据的参照目标的来源, 以及训练期价值网络可接触的信息边界。正因如此, 后续各节对在线方法、行为约束离线基线、双侧正则离线主线方法与生成式先验离线方法的比较, 落在同一组符号与同一套部署约束之内, 成为关于“在固定部署接口下如何利用既有信息与数据”这一核心问题的可相互参照的考察, 而非互不相干的算法堆叠。

5.5 在线情形下的可学习性与信息瓶颈

§5.1 把在线情形定位为离线结果的解释基准: 它考察任务在仅有单点局部感知时能否经由在线交互学会, 以及性能受何种因素制约。本节以在线最大熵方法 SAC (§5.4.2) 在 §5.3.1 给定的两个流动工况上回答这一问题。在亚临界主工况, 可部署的单点传感配置已具备基础可学习性; 转入临界工况后, 可部署配置与更丰富空间感知之间出现显著的性能差距, 一组单变量消融将这一差距归因于策略对单点观测的时序利用, 而非传感硬件或价值估计的不足。这一归因为全章奠定一个基调: 在固定的部署传感接口下, 可部署性能的瓶颈主要落在如何利用既有观测, 而不在于是否为系统增添新的感知能力; 它将在离线情形与失效边界的考察中反复得到印证与界定。

表 5.6: 亚临界主工况 ($Re = 150$ 、 $U_\infty = 1.0$ m/s) 横流穿越任务下三种传感配置的在线可学习性。采用历史效率导向奖励、 $k = 4$ 历史堆叠, 三次重复训练、每次评估 30 回合, 报告均值 $\pm$ 标准差。成功率为质心进入目标半径内的回合占比, 路径效率为成功回合的航程效率 (越接近 1 表示路径越省)。粗体为各列最优。

传感配置	成功率	路径效率
s_0 (可部署, 单点 DVL)	0.789 ± 0.211	0.801 ± 0.057
s_1 (+ 短程 ADCP, 参照上界)	0.967 ± 0.027	0.854 ± 0.024
s_2 (+ 长程 ADCP, 参照上界)	0.856 ± 0.204	0.813 ± 0.100

5.5.1 亚临界工况下的可学习性与传感配置

作为后续比较的前提, 先在亚临界主工况下筛查三种传感配置的基础可学习性。任务为 §5.3.1 所述的横流穿越, 流动取来流 $U_\infty = 1.0$ m/s、雷诺数 $Re = 150$; 三种传感配置 s_0 、 s_1 、 s_2 (§5.3.2, 表 5.1) 在历史效率导向奖励下均以 $k = 4$ 历史堆叠送入标准 SAC 训练, 并在固定评估集上以确定性策略评估。表 5.6 给出三种配置的任务成功率与成功回合的路径效率。

三种传感配置在这一工况下都达到可观的成功率, 最弱者亦不低于 0.78, 表明在亚临界尾流中任务对各传感配置均可学, 无须先验地排除任何一种。可部署的单点配置 s_0 成功率为 0.789, 与最优的 s_1 之间虽存在差距, 但其绝对水平已足以支撑可靠的横流穿越, 路径效率 (0.801) 亦与 s_1 (0.854) 相近, 说明在简单工况中仅凭单点流速即可学得高质量的运动规划。然而, 信息最丰富的 s_2 并未取得最高且最稳的表现: 其成功率 (0.856) 低于 s_1 , 且训练结果的离散度 (标准差 0.204) 远大于 s_1 (0.027)。更多的观测通道在此并未转化为更稳定的训练, 反因输入维度升高而抬高了收敛难度, 初步提示传感信息的丰富程度与可部署性能之间并非单调对应。

上述结果取自亚临界主工况的横流穿越任务, 其结论限于这一相对易学的设定。在临界工况下, 标准 SAC 在相同训练预算内已不能从单点观测稳定学得有效策略; 这一局限的来源, 是下一子节的考察对象。

5.5.2 临界工况下部分可观测性差距的显现

将工况推进到临界区间, 可部署单点感知的局限才充分暴露。自本节起, 分析改用本章正式的到达导向奖励, 流动取 $U_\infty = 1.5$ m/s、 $Re = 250$, 涡旋更强、脱落更快, 速度比 $\lambda = 1.0$ 使航行器形成稳定对地位移的速度余量大幅收缩。在此工况下, 仅用单点观测且仅作 $k = 4$ 历史堆叠的可部署配置几乎无法完成横流穿越任务: 其最终成功率仅约 0.10, 约三分之二回合因越出流场边界而失败 (越界率 0.667)。同一任务下, 仅增设一处前向探针的空间参照配置 s_1 即达到 0.90 的成功率, 越界率降至 0.10。可部署配置与空间参照之间由此张开约 80 个百分点的成功率差距, 标示出临界工况下单点局部可观测所付出的代价。

这一差距可能源于若干不同性质的瓶颈。一种可能是单点观测本身携带的空间信息不足, 须以更多探针在空间上补足; 另一种是价值网络对动作价值的估计不够准确, 使策略改进的方向失真;

还有一种是策略网络未能充分利用单点观测随时间的变化,因而损失了本可从时序中恢复的流场信息。这三者指向截然不同的干预——增设空间探针、改善价值估计、延长观测时序——对部署可行性也意味着不同的判断。它们是部署接口下可供干预的几条主要途径;下面以一组单变量消融逐一甄别,每次只改变基线配置中的一个因素、冻结其余训练条件,从而将成功率的变化明确归因于该因素。

5.5.3 瓶颈的判别: 特权信息与时序访问的单变量消融

判别从价值一侧入手,检验差距是否源于价值估计的不足。沿用 §5.4.6 给出的特权协议,在策略网络只读单点观测、唯一改变价值网络可见信息的前提下,向价值网络注入沿船体的等效来流估计这一特权观测 [Pinto et al., 2018]。配对复现表明,这一改动并未缩小差距,反而使最终成功率由标准 SAC 的 0.220 降至 0.066,训练过程中可达到的峰值成功率亦稳定锁定在 0.267,明显低于空间参照配置;峰值的这一稳定性提示它更可能反映该信息配置的限制,而非随机波动。价值网络获得更完整的流场信息后,所学策略的行为风格确有改变,更倾向于规避边界、推进也更积极,但策略一侧仅有的单点观测不足以把价值网络认可的改进兑现为任务级的成功。可见差距并不出在价值网络的估计精度:把训练期才有的特权信息提供给价值网络反而扰动了策略改进,瓶颈落在策略一侧可获取的信息,而非价值一侧的估计能力。

另一组消融转而作用于策略一侧的信息。在同一可部署基线上,唯一改变的是策略网络的观测历史长度,由 $k = 4$ 增至 $k = 8$,即把送入策略的时序窗由约 2 s 扩展到约 4 s (控制周期 $\Delta t_{\text{ctrl}} = 0.5$ s)。在这一受控对照下,可部署配置的成功率从 0.100 升至 0.900、越界率由 0.667 降至 0.100,在最终成功率、收敛峰值与越界率上均追平空间参照配置 s_1 ,且收敛更快,峰值出现提前约 25 万步;这一追平在重复训练间的稳健性见 §5.5.4。值得对照的是,低维的空间参照配置 s_1 以更短的历史即可达到同等水平,可见高成功率并不依赖更高的输入维度,时序窗延长带来的增益因而不能归于输入规模的扩大。两组消融形成鲜明对照:把等效来流信息提供给价值网络,任务级成功率不升反降;把同等数量级的时序信息提供给策略网络,成功率则恢复到与空间参照一致的水平。表 5.7 汇总了这一对照。

这一对照可由如下物理机制解释。临界工况下驱动航行器的主导扰动是周期性的涡街脱落;单点探针虽只测得当前位置的瞬时流速,但其随时间的变化编码了这一周期性脉动的相位。当策略只能看到单帧观测时,它无法区分同一流速值处于脉动的上升相还是下降相;而当时序窗覆盖脱涡周期的相当比例时,策略便可能从单点流速的时序节拍中反演出主导脉动的相位,进而预判流场的演变。这一相位信息很可能对应于价值网络在特权协议下通过沿船体等效来流所获取的同一脉动量。若如此,则可部署的单点传感并不缺少这一信息,只是它分布在时间维度而非空间维度上;空间上多设探针与时间上延长历史,便是获取同一相位信息的两条途径,而后者无须任何部署阶段不可得的传感。

表 5.7: 临界工况 ($Re = 250$ 、 $U_\infty = 1.5 \text{ m/s}$) 横流穿越任务下时序访问与空间感知对可部署性能的作用, 采用到达导向奖励。三行为单变量受控对照, 每次只改变所标变量、冻结其余训练条件。越界率为因越出流场边界而失败的回合占比。延长历史至 $k = 12$ 后该追平在重复训练间的稳健性, 以及向价值网络注入特权观测的配对消融 (并不缩小差距), 均见正文。

配置 (唯一变量)	成功率	越界率
可部署基线 s_0 , $k = 4$	0.100	0.667
空间参照 s_1 , $k = 4$	0.900	0.100
可部署 s_0 + 时序窗 $k = 8$	0.900	0.100

5.5.4 时序闭合效应的稳健性与评估集上界

单次受控对照上的追平尚不足以确立结论, 时序访问闭合差距的效应须在重复训练间稳健成立, 并区别于优化噪声与初始化的偶然影响。在 $k = 8$ 时, 这一增益在重复训练间尚不稳定, 部分训练仍显著落后于空间参照。将历史长度增至 $k = 12$ (时序窗约 6 s) 后, 重复训练一致收敛到接近评估集所允许上界的水平, 离散度降至 0.038, 远低于全章预设的稳健阈值。更值得重视的是其趋势: 随着历史长度延长, 性能在重复训练间系统性提升, 并在 $k = 8$ 与 $k = 12$ 之间出现明显跃迁。这一系统性趋势排除了两种竞争解释——初始化造成的局部极小不会随历史长度增加而被一致清除, 纯粹的优化噪声也不会沿历史长度呈现一致改善。性能随策略可用时序信息稳定提升, 与信息瓶颈的解释相符。

时序访问所能达到的上限, 进一步受评估集本身的约束。在重复的单点观测训练中, 同一评估集里有三个特定回合始终未能完成, 均因越出流场边界而失败; 这使该协议下的经验成功率上界约为 27/30, 即 0.900。受重复次数所限, 这是观测到的经验上界而非严格的不可达性证明, 但它在所考察的历史长度与多次训练中稳定复现, 提示评估集中存在对单点观测尤为困难的少数回合。延长历史至 $k = 12$ 后, 多数训练已达到这一上界, 余下与之相差的, 主要是一个时序窗延长仍未克服的临界回合 (该回合已推进至距目标约 5 m 处, 几近完成)。可见时序访问不仅在总体水平上闭合了差距, 更把可部署配置推到了该评估集对单点观测所允许的上界附近。

5.5.5 对可部署策略设计的含义

上述在线证据在本章的核心线索上给出一个明确的方向。临界工况下可部署性能的瓶颈, 不在传感硬件的丰富程度, 而在策略对既有单点观测的时序利用: 把流场相位信息从时间维度上充分提取出来, 比在空间上增设探针或在训练期为价值网络注入特权信息更直接地决定了可部署性能。这并不意味着空间感知没有作用: 增设前向探针的 s_1 确实闭合了差距, 但空间探针在部署中不可得, 其所提供的相位信息又可由对单点观测的充分时序利用替代; 至于在训练期向价值网络注入特权信息, 则根本不闭合这一差距。因此, 面向部署的改进路径不必指向更换或增设传感器, 而可落在如何让策略更充分地利用单点观测的时序结构之上。


这一结论也划出了在线情形的性能下界。在临界工况下, 仅用单点观测且不延长时序窗时, 标

准 SAC 的成功率仅约 10%，任务在在线交互下几近失败。本章在后续考察失效边界时，将以这一在线最低水平为参照，对照离线情形在更强信息条件下所能达到的表现，从而界定单点局部感知在何种工况下仍支持可部署策略、又在何处触及不可逾越的边界。

5.5.6 实施细节与可复现性

亚临界工况的传感可行性筛查在横流穿越任务上以标准 SAC 训练，三种传感配置各取三随机种子，每次训练 60 万步，并行环境数固定为 6，每万步在固定评估集上以确定性策略评估 30 回合；该筛查采用历史效率导向奖励，作为本章早期设定，其结论限于传感配置间的相对可学习性。所采用的历史效率导向奖励配置由一组奖励权重筛选实验确定，该筛选在较短训练预算下进行，其绝对成功率不足以作为性能基线，仅用于确定权重设定；正式的可学习性与瓶颈分析均改用到达导向奖励。

临界工况的瓶颈分析在横流穿越任务上以标准 SAC 训练，每次训练 100 万步，并行环境数为 6，采用到达导向奖励与 s_0 单点传感。特权信息消融在上述基线上唯一启用价值网络的特权观测通道，策略网络保持单点观测，取两随机种子作配对复现；时序访问消融在同一基线上唯一改变观测历史长度 ($k \in \{4, 8, 12\}$)， $k = 8$ 与 $k = 12$ 分别取三随机种子。评估集经验上界由五次单点观测训练在同一评估集上的逐回合越界情况统计得到：当某一回合在全部训练中均失败时，将其计入难以达成的回合。各项消融均只改变所述的单一因素，其余训练超参数、随机种子规模与评估协议 (§5.3.6) 保持一致；本节报告各项的随机种子数量与每种子评估回合数，具体随机种子编号保留于复现实验配置与结果记录。



(b) Deployable vs. privileged sensor sampling

Body-frame (not to scale)




图 5.1: 任务与传感协议示意。(a) 二维双弛豫时间格子玻尔兹曼方法离线生成的卡门涡街尾流场 (亚临界工况 $U_\infty = 1.0$ m/s、 $Re = 150$ 、湍流强度 5%) 某一帧的涡量背景, 叠加 REMUS-100 体示意 (黄色椭圆, 红色箭头为体轴朝向) 与横流穿越任务目标 (绿色五角星)。(b) 体坐标系下两种传感抽样协议: 蓝色实心圆 s_0 是部署可得的单点 DVL 水追踪, 策略网络在两种协议下都只读此通道; 红色菱形为沿体轴的 $\xi_i \in \{-0.4, -0.2, 0, +0.2, +0.4\} \cdot L$ 五个等距采样点, 等权平均后给出沿机体采样等效来流 $\mathbf{o}^{priv} = [u_{eq}, v_{eq}]$, 仅在特权协议训练阶段被价值网络读取, 部署阶段不可用 ((5.1))。

参考文献

- Dian Chen, Brady Zhou, Vladlen Koltun, and Philipp Krähenbühl. Learning by cheating. In *Proceedings of the Conference on Robot Learning (CoRL)*, volume 100 of *Proceedings of Machine Learning Research*, pages 66–75, 2020.
- Simona Colabrese, Kristian Gustavsson, Antonio Celani, and Luca Biferale. Flow navigation by smart microswimmers via reinforcement learning. *Physical Review Letters*, 118:158004, 2017. doi: 10.1103/PhysRevLett.118.158004.
- Sheryl Coombs, Joseph Bak-Coleman, and John Montgomery. Rheotaxis revisited: A multi-behavioral and multisensory perspective on how fish orient to flow. *Journal of Experimental Biology*, 223:jeb223008, 2020. doi: 10.1242/jeb.223008.
- Valentina Di Santo and Elsa Goerig. Swimming smarter, not harder: Fishes exploit habitat heterogeneity to increase locomotor performance. *Journal of Experimental Biology*, 228(Suppl_1): JEB247918, 2025. doi: 10.1242/jeb.247918.
- Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Monographs on Statistics and Applied Probability. Chapman & Hall, New York, 1993.
- Hao-Dong Feng, De-Hua Yuan, Jia-Liang Miao, et al. Efficient navigation of a robotic fish swimming across the vortical flow field. *Journal of Hydrodynamics*, 36:1118–1129, 2025. doi: 10.1007/s42241-025-0103-5.
- Yoav Flato, Roi Harel, Aviv Tamar, Ran Nathan, and Tsevi Beatus. Revealing principles of autonomous thermal soaring in windy conditions using vulture-inspired deep reinforcement learning. *Nature Communications*, 15:4942, 2024. doi: 10.1038/s41467-024-48670-x.
- Thor I. Fossen. *Handbook of Marine Craft Hydrodynamics and Motion Control*. John Wiley & Sons, 2011.
- Scott Fujimoto and Shixiang Shane Gu. A minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

- Scott Fujimoto, Herke van Hoof, and David Meger. Addressing function approximation error in actor-critic methods. In *International Conference on Machine Learning (ICML)*, 2018.
- Scott Fujimoto, David Meger, and Doina Precup. Off-policy deep reinforcement learning without exploration. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019.
- Peter Gunnarson, Ioannis Mandralis, Guido Novati, Petros Koumoutsakos, and John O. Dabiri. Learning efficient navigation in vortical flow fields. *Nature Communications*, 12:7143, 2021. doi: 10.1038/s41467-021-27015-y.
- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018.
- Yusheng Jiao, Haotian Hang, Josh Merel, and Eva Kanso. Sensing flow gradients is necessary for learning autonomous underwater navigation. *Nature Communications*, 16:3044, 2025. doi: 10.1038/s41467-025-58125-6.
- Borko D. Jovanovic and Paul S. Levy. A look at the rule of three. *The American Statistician*, 51(2):137–139, 1997. doi: 10.1080/00031305.1997.10473947.
- Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit q-learning. In *International Conference on Learning Representations (ICLR)*, 2022.
- Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- Sergey Levine, Aviral Kumar, George Tucker, and Justin Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems, 2020.
- Liang Li, Máté Nagy, Jacob M. Graving, Joseph Bak-Coleman, Guangming Xie, and Iain D. Couzin. Vortex phase matching as a strategy for schooling in robots and in fish. *Nature Communications*, 11:5408, 2020. doi: 10.1038/s41467-020-19086-0.
- James C. Liao. Fish swimming efficiency. *Current Biology*, 32(12):R666–R671, 2022. doi: 10.1016/j.cub.2022.04.073.
- Selim Mecanna, Aurélie Loisy, and Christophe Eloy. A critical assessment of reinforcement learning methods for microswimmer navigation in complex flows. *European Physical Journal E*, 48:58, 2025. doi: 10.1140/epje/s10189-025-00522-2.

- Navid Mousavi, Jingran Qiu, Bernhard Mehlig, Lihao Zhao, and Kristian Gustavsson. Efficient survival strategy for zooplankton in turbulence. *Physical Review Research*, 6:L022034, 2024. doi: 10.1103/PhysRevResearch.6.L022034.
- Seohong Park, Qiyang Li, and Sergey Levine. Flow q-learning, 2025.
- Lerrel Pinto, Marcin Andrychowicz, Peter Welinder, Wojciech Zaremba, and Pieter Abbeel. Asymmetric actor critic for image-based robot learning. In *Proceedings of Robotics: Science and Systems (RSS)*, 2018.
- Jingran Qiu, Navid Mousavi, Kristian Gustavsson, and Bernhard Mehlig. Navigation of microswimmers in steady flow: The importance of symmetries. *Journal of Fluid Mechanics*, 932:A10, 2022. doi: 10.1017/jfm.2022.258.
- Denis Tarasov, Vladislav Kurenkov, Alexander Nikulin, and Sergey Kolesnikov. Revisiting the minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- Vladimir Vapnik and Akshay Vashist. A new learning paradigm: Learning using privileged information. *Neural Networks*, 22(5–6):544–557, 2009. doi: 10.1016/j.neunet.2009.06.042.
- Siddhartha Verma, Guido Novati, and Petros Koumoutsakos. Efficient collective swimming by harnessing vortices through deep reinforcement learning. *Proceedings of the National Academy of Sciences (PNAS)*, 115(23):5849–5854, 2018. doi: 10.1073/pnas.1800923115.
- B. L. Welch. The generalization of ‘student’s’ problem when several different population variances are involved. *Biometrika*, 34(1–2):28–35, 1947. doi: 10.1093/biomet/34.1-2.28.
- Yi Zhu, Jian-Hua Pang, and Fang-Bao Tian. Point-to-point navigation of a fish-like swimmer in a vortical flow with deep reinforcement learning. *Frontiers in Physics*, 10:870273, 2022. doi: 10.3389/fphy.2022.870273.