

第五章 局部感知下水下航行器运动规划的强化学习方法

5.1 引言

水生与空中的动物长期栖居于非定常、充满涡旋与剪切的流体环境。这类流动结构在工程控制中通常被视为需要抑制的扰动，许多动物却在演化中获得了相反的能力：感知并顺应周围的流场，将其转化为运动上的收益。以鱼类为例，部分种类能在岩石或桥墩等障碍物诱发的涡街中以特定的身体摆动驻留，借周期性的涡结构降低游动的代谢消耗。支撑这类行为的并非对整个流场的完整测量，而是有限的局部感知；就鱼类而言，这一感知来自沿体表空间分布的侧线阵列，而非任何单一测点 [Liao, 2022, Coombs et al., 2020]。自然界以感知在空间上的分布，弥补了无法测量整个流场的不足。这一借流原则不限于水中，鸟类对热上升气流的利用即为空中的一例 [Flato et al., 2024]。

自主航行器在结构化流场中执行运动规划时，面临相似但更受工程约束的问题。它无法完整测量环境流场，只能依赖板载传感给出的船体附近局部流速或等效流速估计；这种信息不同于鱼类侧线的空间阵列，也不同于可直接输入学习系统的全场流场。由此引出本章的核心问题：在仅有单点局部感知的约束下，强化学习能把这类运动规划推进到何种性能水平？

这一约束在两种学习情形下含义不同。航行器若能与环境在线交互、反复试错，问题在于它能否仅凭单点感知学会运动规划，以及性能受何种因素制约。若在线交互不可行，策略只能从既有控制器采集的数据中离线学习 [Levine et al., 2020]，且部署阶段无法访问训练期才有的特权信息 (privileged information)，例如对真实环境流场的额外测量 [Pinto et al., 2018]，问题便转为策略所能达到的性能上限。后一情形更贴近部署现实：受安全与成本约束的平台往往无法进行大量在线试错，只能复用既有数据，因而构成本章的重心；前一情形则用以确立任务的可学习性、定位性能瓶颈，为离线结果提供解释基准。

这一问题的答案在两个方面偏离直觉。一方面，离线学习对数据质量的依赖远比预期宽松：即便数据仅由简单的可部署控制器采集，所学策略的任务成功率也能追平那些在训练阶段额外向价值网络提供特权信息、而部署策略仍只使用局部输入的同类方法。另一方面，在本章考察的受控基准中，不同传感配置之间的性能差距，并不必然需要更丰富的空间感知来闭合，而可由对单点信号的充分时序利用替代。可行性之外仍存一条明确边界：当环境难度越过某一阈值，部署策略若仍只能使用单点观测，即使训练阶段引入特权观测或特权示范，性能也会受限于部分可观测性所造成的上限。

这些结论均来自一个受控的仿真运动规划基准；其确切的适用范围，包括环境难度、传感配置与任务设定，由后文逐一界定。本章不将它们外推为对一切流场或平台的普遍结论。

本章的贡献在于，将这一部署约束下的运动规划问题转化为一组可检验的判别问题：单点局部感知在何种条件下足以支持有效策略，离线数据中的行为目标何时能够被可靠利用，训练期特权信息和更强策略先验又在哪些边界内不再提供普遍收益。为回答这些问题，本章在共同的部署约束下比较在线策略的 Actor-Critic 方法 [Haarnoja et al., 2018]、行为约束的离线方法 [Fujimoto and Gu, 2021, Tarasov et al., 2023]、更具表达力的生成式策略 [Park et al., 2025]，以及非对称 Actor-Critic 框架下对特权信息的利用 [Pinto et al., 2018]。由此得到的认识不依赖单一算法，而指向该问题本身的性能水平、支配机制与失效边界；后文将通过多随机种子的统计检验加以确立。

这些认识可以收束为一条贯穿全章的线索：在部署约束下，提升性能的关键在于用好已有的信息与数据，而非为系统增添能力。单点观测的时序利用与模仿目标同数据质量的适配，表面上分属传感与离线学习两个层面，实质上都在固定部署接口下提高既有轨迹中可被策略提取的信息量。与之相对，更多空间传感器、向价值网络注入特权观测、采用更具表达力的策略先验，分别代表增加观测、增加训练期信息和增加策略容量。它们或非必需，或不普遍有效。可行性的来源及其边界由这条线索贯穿，而不取决于任何单一算法。

全章余下各节循此线索展开。第 5.2 节梳理相关研究并界定本章定位，第 5.3 节给出各条线索共享的问题设定与评估协议。第 5.4 节确立在线情形下的任务可学习性，并将瓶颈定位于对信号的时序利用。离线情形构成本章重心：第 5.5 节以可部署离线基线界定问题，第 5.6 节回答单点局部感知下离线学习能否达到可部署性能，第 5.7 节刻画这一可行性的失效边界，第 5.8 节经由算法比较辨别决定性能的真正因素，第 5.9 节统一讨论各条线索共同指向的机制。

5.2 研究背景与定位

生物对流场的利用可从两个互补的角度理解：对运动而言，流场既是可资借用的能量来源，也是可供感知的信息来源。就能量而言，鱼类能在涡街与障碍物尾流中降低单体游动的代谢消耗，也能在群体中借尾拍与同伴尾涡之间的相位匹配，减少集体游动的能耗 [Liao, 2022, Di Santo and Goerig, 2025, Li et al., 2020]；这些现象的共同点在于，高效运动来自身体运动与流动结构在时空上的耦合，而非单纯增大推力。就信息而言，支撑上述行为的鱼类侧线是一种沿体表空间分布的感受阵列，而非单点的速度计 [Coombs et al., 2020]；这一结构提示，传感在空间上的组织方式本身，可能决定借流行为的可行性。同一原则在更广的类群与尺度上亦有印证：鸟类借热上升气流实现长距离滑翔，浮游生物则响应湍流中的局部梯度完成输运 [Flato et al., 2024, Mousavi et al., 2024]。

强化学习把这些借流现象从生物观察转化为可建模、可学习的控制问题。奠基性的工作让智能微游泳体在解析流场中学习游动方向以避开不利流区，并借助涡结构提升集体游动的推进效率 [Colabrese et al., 2017, Verma et al., 2018]。其后研究的重心转向局部感知：固定速度的游泳体在给定目标相对信息与局部流速的条件下，可以在非定常涡流中学到接近全局最优的高效轨迹 [Gunnarson et al., 2021]；而在自我中心坐标系下，单一的局部流速往往不足以支撑可靠学习，尚须辅以局部的流场梯度。这一结论恰与鱼类侧线的空间阵列结构相呼应 [Jiao et al., 2025]。更贴近工程实现的具

身研究让柔性鱼形机器人在涡街与圆柱尾流中学习稳健的导航与姿态控制 [Zhu et al., 2022, Feng et al., 2025]; 相关研究还表明, 流场对称性等物理结构会影响所学策略 [Qiu et al., 2022], 并对复杂、局部可观测流场中不同方法的表现作了系统评估 [Mecanna et al., 2025]。

上述借流强化学习的研究大多假设智能体能与环境在线交互, 本章面对的却是只能复用固定数据的离线情形。离线强化学习研究如何仅从一批固定数据中学习策略, 而不与环境继续交互 [Levine et al., 2020]; 其核心困难在于分布偏移: 策略一旦在数据未覆盖的动作上高估价值, 便会偏离数据支持的区域, 又无从在线纠正。围绕这一困难, 已有方法形成几类思路不同的约束方式。一类从策略入手, 将学得策略约束在采集数据的行为分布附近: 早期工作通过对候选动作的显式筛选实现这一约束 [Fujimoto et al., 2019], 其后的极简方法表明, 仅在标准 Actor-Critic 目标上叠加一项行为克隆正则即可达到相当的效果 [Fujimoto and Gu, 2021], 进一步的工作则在策略与价值两侧同时施加这类正则 [Tarasov et al., 2023]。另一类从价值入手, 不显式约束策略, 而对分布外动作的价值作保守估计或隐式回归, 从而回避对未见动作的外推 [Kumar et al., 2020, Kostrikov et al., 2022]。还有一类改变策略本身的表示, 以更具表达力的生成式策略刻画可行动作, 并在价值引导下从固定数据中学习策略 [Park et al., 2025]。这些方式各有侧重, 约束的强弱、表示的繁简之间并无先天的优劣之分; 更具表达力的先验是否换来更好的性能, 取决于数据条件, 第 5.8 节将对此专门考察。

本章涉及的另一条脉络, 处理训练与部署之间的信息不对称。当航行器只能获得部分可观测的局部信息时, 一种常见做法是在训练阶段利用部署时无法获得的额外观测, 即特权信息 (privileged information)。这一概念最初见于监督学习 [Vapnik and Vashist, 2009], 在机器人学中则发展为师生范式: 先用可访问特权信息的教师策略求解任务, 再将其行为蒸馏到只依赖部署传感的学生策略 [Chen et al., 2020]。一种无需显式蒸馏的替代是非对称 Actor-Critic: 训练期的价值网络接收特权观测以稳定学习, 而策略本身始终只依赖部署阶段可得的输入 [Pinto et al., 2018]。这些做法的共同前提是特权信息确有助益、值得在训练期专门加以利用; 至于在仅有单点局部感知的部署约束下, 不借助任何特权信息能否追平借助它所达到的性能, 则尚少被直接追问。

将这几条脉络并置, 便显出一处共同的空白。借流强化学习的研究大多依赖多于单点的流场观测, 或允许智能体在线反复试错; 离线强化学习的方法多在标准基准上验证, 鲜少触及单点局部可观测这一物理传感约束; 利用特权信息的工作则大多预设训练期的特权确有助益, 并设法加以利用。若只有局部感知约束, 在线交互仍可能通过试错补偿观测不足; 若只有离线学习约束, 标准基准又通常不要求策略从物理上受限的单点流速中恢复环境结构; 若允许训练期特权信息, 价值学习或策略蒸馏还可绕开一部分部署传感不足。三者同时成立时, 问题才转化为一个更严格的判别: 固定数据中是否已经包含足够信息, 使只依赖单点部署观测的策略能够恢复可用的运动规划规律。

这一情形是受尺寸、功耗、成本与安全约束平台的一类典型处境, 却至今缺乏系统刻画。它也不是对生物侧线结构的直接仿制; 本章关心的是, 在无法部署空间分布式流场阵列时, 时间上的观测组织和离线数据中的行为目标能否补偿空间信息的缺失。本章即定位于这一交叉处, 在共同的部署约束与多随机种子的统计检验下, 辨明局部感知约束下可行性的来源及其失效边界, 并揭示离线学习内部决定算法高下的真正因素; 这些发现共同指向的机制, 将由后续各节逐一展开。

参考文献

- Dian Chen, Brady Zhou, Vladlen Koltun, and Philipp Krähenbühl. Learning by cheating. In *Proceedings of the Conference on Robot Learning (CoRL)*, volume 100 of *Proceedings of Machine Learning Research*, pages 66–75, 2020.
- Simona Colabrese, Kristian Gustavsson, Antonio Celani, and Luca Biferale. Flow navigation by smart microswimmers via reinforcement learning. *Physical Review Letters*, 118:158004, 2017. doi: 10.1103/PhysRevLett.118.158004.
- Sheryl Coombs, Joseph Bak-Coleman, and John Montgomery. Rheotaxis revisited: A multi-behavioral and multisensory perspective on how fish orient to flow. *Journal of Experimental Biology*, 223:jeb223008, 2020. doi: 10.1242/jeb.223008.
- Valentina Di Santo and Elsa Goerig. Swimming smarter, not harder: Fishes exploit habitat heterogeneity to increase locomotor performance. *Journal of Experimental Biology*, 228(Suppl_1): JEB247918, 2025. doi: 10.1242/jeb.247918.
- Hao-Dong Feng, De-Hua Yuan, Jia-Liang Miao, et al. Efficient navigation of a robotic fish swimming across the vortical flow field. *Journal of Hydrodynamics*, 36:1118–1129, 2025. doi: 10.1007/s42241-025-0103-5.
- Yoav Flato, Roi Harel, Aviv Tamar, Ran Nathan, and Tsevi Beatus. Revealing principles of autonomous thermal soaring in windy conditions using vulture-inspired deep reinforcement learning. *Nature Communications*, 15:4942, 2024. doi: 10.1038/s41467-024-48670-x.
- Scott Fujimoto and Shixiang Shane Gu. A minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- Scott Fujimoto, David Meger, and Doina Precup. Off-policy deep reinforcement learning without exploration. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019.
- Peter Gunnarson, Ioannis Mandralis, Guido Novati, Petros Koumoutsakos, and John O. Dabiri. Learning efficient navigation in vortical flow fields. *Nature Communications*, 12:7143, 2021. doi: 10.1038/s41467-021-27015-y.

- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018.
- Yusheng Jiao, Haotian Hang, Josh Merel, and Eva Kanso. Sensing flow gradients is necessary for learning autonomous underwater navigation. *Nature Communications*, 16:3044, 2025. doi: 10.1038/s41467-025-58125-6.
- Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit q-learning. In *International Conference on Learning Representations (ICLR)*, 2022.
- Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- Sergey Levine, Aviral Kumar, George Tucker, and Justin Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems, 2020.
- Liang Li, Máté Nagy, Jacob M. Graving, Joseph Bak-Coleman, Guangming Xie, and Iain D. Couzin. Vortex phase matching as a strategy for schooling in robots and in fish. *Nature Communications*, 11:5408, 2020. doi: 10.1038/s41467-020-19086-0.
- James C. Liao. Fish swimming efficiency. *Current Biology*, 32(12):R666–R671, 2022. doi: 10.1016/j.cub.2022.04.073.
- Selim Mecanna, Aurélie Loisy, and Christophe Eloy. A critical assessment of reinforcement learning methods for microswimmer navigation in complex flows. *European Physical Journal E*, 48:58, 2025. doi: 10.1140/epje/s10189-025-00522-2.
- Navid Mousavi, Jingran Qiu, Bernhard Mehlig, Lihao Zhao, and Kristian Gustavsson. Efficient survival strategy for zooplankton in turbulence. *Physical Review Research*, 6:L022034, 2024. doi: 10.1103/PhysRevResearch.6.L022034.
- Seohong Park, Qiyang Li, and Sergey Levine. Flow q-learning, 2025.
- Lerrel Pinto, Marcin Andrychowicz, Peter Welinder, Wojciech Zaremba, and Pieter Abbeel. Asymmetric actor critic for image-based robot learning. In *Proceedings of Robotics: Science and Systems (RSS)*, 2018.
- Jingran Qiu, Navid Mousavi, Kristian Gustavsson, and Bernhard Mehlig. Navigation of microswimmers in steady flow: The importance of symmetries. *Journal of Fluid Mechanics*, 932:A10, 2022. doi: 10.1017/jfm.2022.258.

- Denis Tarasov, Vladislav Kurenkov, Alexander Nikulin, and Sergey Kolesnikov. Revisiting the minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- Vladimir Vapnik and Akshay Vashist. A new learning paradigm: Learning using privileged information. *Neural Networks*, 22(5–6):544–557, 2009. doi: 10.1016/j.neunet.2009.06.042.
- Siddhartha Verma, Guido Novati, and Petros Koumoutsakos. Efficient collective swimming by harnessing vortices through deep reinforcement learning. *Proceedings of the National Academy of Sciences (PNAS)*, 115(23):5849–5854, 2018. doi: 10.1073/pnas.1800923115.
- Yi Zhu, Jian-Hua Pang, and Fang-Bao Tian. Point-to-point navigation of a fish-like swimmer in a vortical flow with deep reinforcement learning. *Frontiers in Physics*, 10:870273, 2022. doi: 10.3389/fphy.2022.870273.