

第五章 面向可部署传感的水下航行器尾流导航离线强化学习

5.1 引言

自主航行器要在真实环境中可靠导航，必须应对一个自身无法完整观测的环境流场：流场在空间上非均匀、随时间演化，并持续作用于整个载体而改变其运动，而航行器在部署时通常只能在自身所在的一点测得局部流速。这使得导航在本质上成为一个在部分可观测的外部流场中持续决策的问题——驱动动力学的是作用于整个载体的流场，可获得的却只是单点、瞬时的测量。这类流场高度非线性且非定常，难以用手工设计的固定控制律充分利用，因而成为强化学习等数据驱动方法的自然对象 [Gunnarson et al., 2021, Verma et al., 2018]。然而，已有工作大多假设可获得较丰富的流场观测或允许在线交互，而真实部署所受的更严格约束——仅有单点传感、且只能从既有数据离线学习——在何种条件下仍然可行，尚缺乏系统刻画。

本章因此提出一个直接的问题：在仅有局部感知的约束下，强化学习能把这类导航推进到何种性能水平？这一问题有两个面向：其一，当航行器能与环境在线交互、反复试错时，它能否仅凭局部感知学会导航，又是什么在限制其性能；其二，也是本章的重点，当无法在线交互、只能从既有控制器采集的数据中离线学习 [Levine et al., 2020]，且部署阶段不可访问任何特权信息（仅在训练阶段可得、对真实流场的额外观测 [Pinto et al., 2018]）时，策略能达到的性能上限为何。后一设定更贴近部署现实：受约束的平台往往无法安全或经济地进行大量在线试错，只能复用既有数据。本章据此先以在线情形确立任务的可学习与瓶颈所在，再以此为基础回答作为核心贡献的离线情形。

本章的回答有三层，其中前两层与直觉相悖。第一，在离线情形下，仅凭简单可部署控制器采集的数据，学到的策略在任务成功率上即可达到与训练阶段可利用特权信息的方法相当的水平，而部署时无需任何特权信息。第二，闭合不同传感配置之间的性能差距，关键并不在于更丰富的空间感知（增设传感探头），而在于对单点信号的时序利用。第三，上述结论仅在一定的环境难度内成立：超过某一阈值后，会出现一个即便提供特权信息也无法突破的性能上限，且采用表达力更强的学习算法亦无普遍优势。

需要强调，这些结论是在一个受控的仿真导航基准上得到的；其确切适用边界——环境难度、传感配置与任务设定——将在后文逐一界定，本章并不将其外推为对一切流场或平台的普遍结论。

与多数强化学习研究不同，本章的贡献不在于提出新的学习算法，而在于关于“何种因素决

定成败”的实证结论。所采用的算法与训练协议——在线 off-policy actor-critic、行为约束的离线方法、更具表达力的生成式策略，以及非对称 actor-critic 框架下的特权信息利用——均为已有成果 [Fujimoto and Gu, 2021, Tarasov et al., 2023, Kostrikov et al., 2022, Pinto et al., 2018]；本章的新意在于将它们置于同一受控的部署设定下，以统一的评估协议与多随机种子的统计检验，得到一组相互印证的结论：

- 确立局部信息导航的可学习性，并表明其瓶颈在于对部署信号的时序利用，而非空间传感的丰富程度；
- 表明仅凭可部署传感采集的离线数据，即可使策略达到与利用特权信息的方法相当的性能，而部署阶段无需任何特权信息；
- 刻画这一结论的失效边界：超过一定环境难度后，性能受限于一个连特权示范与特权信息也无法突破的上限；
- 表明算法的相对优劣取决于数据的质量与特性——起决定作用的是被模仿的行为数据与所处条件之间的适配，而非策略类的表达能力。

贯穿这四点的，是两个起决定作用的因素：策略对部署信号的时序利用，以及离线学习中模仿目标与数据条件的适配。

本章其余部分相应地分为两部分。在此之前，先梳理相关工作并界定本章定位，再给出三条研究线索共享的统一问题设定与评估协议。第一部分研究在线情形，确立任务的可学习性，并将性能瓶颈定位于对信号的时序利用；第二部分研究离线情形，也是本章的重点：先以一个可部署的离线基线方法界定问题，继而给出核心的可行性结果，随后刻画其失效边界，最后通过算法比较揭示决定性能的真正因素。全章最后统一讨论各条线索共同指向的机制。

参考文献

- Scott Fujimoto and Shixiang Shane Gu. A minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- Peter Gunnarson, Ioannis Mandralis, Guido Novati, Petros Koumoutsakos, and John O. Dabiri. Learning efficient navigation in vortical flow fields. *Nature Communications*, 12:7143, 2021. doi: 10.1038/s41467-021-27015-y.
- Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit q-learning. In *International Conference on Learning Representations (ICLR)*, 2022.
- Sergey Levine, Aviral Kumar, George Tucker, and Justin Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems, 2020.
- Lerrel Pinto, Marcin Andrychowicz, Peter Welinder, Wojciech Zaremba, and Pieter Abbeel. Asymmetric actor critic for image-based robot learning. In *Proceedings of Robotics: Science and Systems (RSS)*, 2018.
- Denis Tarasov, Vladislav Kurenkov, Alexander Nikulin, and Sergey Kolesnikov. Revisiting the minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- Siddhartha Verma, Guido Novati, and Petros Koumoutsakos. Efficient collective swimming by harnessing vortices through deep reinforcement learning. *Proceedings of the National Academy of Sciences (PNAS)*, 115(23):5849–5854, 2018. doi: 10.1073/pnas.1800923115.