

第五章 局部感知下水下航行器运动规划的强化学习方法

5.1 引言

鱼类在河流中游动、鸟类在大气中飞行时，周围介质往往并非静止均匀。障碍物尾流、涡街、剪切层和热上升气流都会改变运动体相对于环境的受力与能耗。在工程控制中，这类非定常流动通常被视为外界扰动；生物运动研究则表明，局部感知与姿态调节也可能使运动体从环境流动中获得推进或节能条件。以鱼类为例，部分种类能在障碍物诱发的涡街中通过特定身体摆动维持位置，借周期性涡结构降低游动代谢消耗。支撑这类行为的并非对整个流场的完整测量，而是有限的局部感知；就鱼类而言，这一感知来自沿体表空间分布的侧线阵列，而非任何单一测点 [Liao, 2022, Coombs et al., 2020]。鸟类对热上升气流的利用也说明，运动体可以在局部感知和运动调节的共同作用下利用环境流动 [Flato et al., 2024]。

自主水下航行器（autonomous underwater vehicle, AUV）在尾流等结构化流场中执行运动规划时，面对的是相似但更受工程条件限制的问题。AUV 无法完整测量环境流场，只能依赖板载传感给出的局部流速或等效流速估计；这种信息不同于鱼类侧线的空间阵列，也不同于可直接输入学习系统的全场流场。由此引出本章的核心问题：在仅有单点局部感知的约束下，强化学习在何种条件下仍能形成可部署的运动规划策略？

这一约束在两种学习情形下含义不同。航行器若能与环境在线交互、反复试错，问题在于它能否仅凭单点感知学会运动规划，以及性能受何种因素制约。若在线交互不可行，策略只能从既有控制器采集的数据中离线学习 [Levine et al., 2020]，且部署阶段无法访问训练期才有的特权信息（privileged information），例如只在训练中可得的动力学有效流速信息 [Pinto et al., 2018]，问题便转为策略所能达到的性能上限。后一情形更贴近部署现实：受安全与成本约束的平台往往无法进行大量在线试错，只能复用既有数据，因而构成本章的重心；前一情形则用以考察任务在在线交互下的可学习性，并为离线结果提供解释基准。

本章围绕这一问题展开三组判别。其一，离线学习对数据质量的依赖是否必然严苛，还是在简单可部署控制器采集的数据中也可能恢复有效策略；其二，不同传感配置之间的性能差距，是否必须依赖更丰富的空间感知来闭合，还是可以由对单点信号的充分时序利用部分替代；其三，当环境难度越过某一阈值，策略若仍只能使用单点观测，训练阶段的特权观测或特权示范是否仍足以突破部分可观测性造成的上限。

这些判别均限于一个受控的仿真运动规划基准；其确切的适用范围，由本章的环境难度、传感配置与任务设定共同限定。本章不将它们外推为对一切流场或平台的普遍结论。

本章的贡献在于，将这一部署约束下的运动规划问题转化为一组可检验的判别问题：单点局部感知在何种条件下足以支持有效策略，离线数据中的行为目标何时能够被可靠利用，训练期特权信息和更强策略先验又在何种边界内改变可部署性能。为回答这些问题，本章在共同的部署约束下比较在线异策略的 Actor-Critic 方法 [Haarnoja et al., 2018]、行为约束的离线方法 [Fujimoto and Gu, 2021, Tarasov et al., 2023]、更具表达力的生成式策略 [Park et al., 2025]，以及非对称 Actor-Critic 框架下对特权信息的利用 [Pinto et al., 2018]。由此形成的认识不依赖单一算法的偶然表现，而指向该问题本身的性能水平、支配机制与适用边界，并以多随机种子的统计检验约束相关判断。

本章据此提出一条贯穿全章的待检验线索：在部署约束下，可部署性能的提升可能更多依赖于对已有信息与数据的有效利用，而不是简单依赖于为系统增添能力。单点观测的时序利用与模仿目标同数据质量的适配，表面上分属传感与离线学习两个层面，实质上都在固定部署接口下提高既有轨迹中可被策略提取的信息量。与之相对，更多空间传感器、向价值网络注入特权观测、采用更具表达力的策略先验，分别代表增加观测、增加训练期信息和增加策略容量。它们是否必要、在何种条件下有效，构成本章的核心检验对象。可行性的来源及其边界由这条线索贯穿，而不取决于任何单一算法。

全章余下各节循此线索展开。第 5.2 节梳理相关研究并界定本章定位，第 5.3 节给出各条线索共享的问题设定与评估协议。第 5.4 节考察在线情形下的任务可学习性及信号时序利用问题。离线情形构成本章重心：第 5.5 节给出可部署离线基线，第 5.6 节检验单点局部感知下离线学习能否达到可部署性能，第 5.7 节讨论这一可行性的边界，第 5.8 节比较不同算法与数据条件下的表现，第 5.9 节综合讨论各条线索共同指向的机制。

5.2 研究背景与定位

生物对流场的利用可从两个互补的角度理解：对运动而言，流场既是可资借用的能量来源，也是可供感知的信息来源。就能量而言，鱼类能在涡街与障碍物尾流中降低单体游动的代谢消耗，也能在群体中借尾拍与同伴尾涡之间的相位匹配，减少集体游动的能耗 [Liao, 2022, Di Santo and Goerig, 2025, Li et al., 2020]；这些现象的共同点在于，高效运动来自身体运动与流动结构在时空上的耦合，而非单纯增大推力。就信息而言，支撑上述行为的鱼类侧线是一种沿体表空间分布的感受阵列，而非单点的速度计 [Coombs et al., 2020]；这一结构提示，传感在空间上的组织方式本身，可能决定借流行为的可行性。同一原则在更广的类群与尺度上亦有印证：鸟类借热上升气流实现长距离滑翔，浮游生物则响应湍流中的局部梯度完成输运 [Flato et al., 2024, Mousavi et al., 2024]。

强化学习把这些借流现象从生物观察转化为可建模、可学习的控制问题。奠基性的工作让智能微游泳体在解析流场中学习游动方向以避开不利流区，并借助涡结构提升集体游动的推进效率 [Colabrese et al., 2017, Verma et al., 2018]。其后研究的重心转向局部感知：固定速度的游泳体在给定目标相对信息与局部流速的条件下，可以在非定常涡流中学到接近全局最优的高效轨迹 [Gunnarson et al., 2021]；而在自我中心坐标系下，单一的局部流速往往不足以支撑可靠学习，尚须辅以局部的

流场梯度。这一结论恰与鱼类侧线的空间阵列结构相呼应 [Jiao et al., 2025]。更贴近工程实现的具身研究让柔性鱼形机器人在涡街与圆柱尾流中学习稳健的导航与姿态控制 [Zhu et al., 2022, Feng et al., 2025]；相关研究还表明，流场对称性等物理结构会影响所学策略 [Qiu et al., 2022]，并对复杂、局部可观测流场中不同方法的表现作了系统评估 [Mecanna et al., 2025]。

上述借流强化学习的研究大多假设智能体能与环境在线交互，本章面对的却是只能复用固定数据的离线情形。离线强化学习研究如何仅从一批固定数据中学习策略，而不与环境继续交互 [Levine et al., 2020]；其核心困难在于分布偏移：策略一旦在数据未覆盖的动作上高估价值，便会偏离数据支持的区域，又无从在线纠正。围绕这一困难，已有方法形成几类思路不同的约束方式。一类从策略入手，将学得策略约束在采集数据的行为分布附近：早期工作通过对候选动作的显式筛选实现这一约束 [Fujimoto et al., 2019]，其后的极简方法表明，仅在标准 Actor-Critic 目标上叠加一项行为克隆正则即可达到相当的效果 [Fujimoto and Gu, 2021]，进一步的工作则在策略与价值两侧同时施加这类正则 [Tarasov et al., 2023]。另一类从价值入手，不显式约束策略，而对分布外动作的价值作保守估计或隐式回归，从而回避对未见动作的外推 [Kumar et al., 2020, Kostrikov et al., 2022]。还有一类改变策略本身的表示，以更具表达力的生成式策略刻画可行动作，并在价值引导下从固定数据中学习策略 [Park et al., 2025]。这些方式各有侧重，约束的强弱、表示的繁简之间并无先天的优劣之分；在本章所关心的固定数据与部署受限传感条件下，关键问题转为这些约束与表示方式能否在不同数据质量下稳定转化为可部署策略的性能收益。

本章涉及的另一条脉络，处理训练与部署之间的信息不对称。当航行器只能获得部分可观测的局部信息时，一种常见做法是在训练阶段利用部署时无法获得的额外观测，即特权信息 (privileged information)。这一概念最初见于监督学习 [Vapnik and Vashist, 2009]，在机器人学中则发展为师生范式：先用可访问特权信息的教师策略求解任务，再将其行为蒸馏到只依赖部署传感的学生策略 [Chen et al., 2020]。一种无需显式蒸馏的替代是非对称 Actor-Critic：训练期的价值网络接收特权观测以稳定学习，而策略本身始终只依赖部署阶段可得的输入 [Pinto et al., 2018]。这些做法的共同前提是特权信息确有助益、值得在训练期专门加以利用；至于在仅有单点局部感知的部署约束下，不借助任何特权信息时，可部署策略能否接近同类特权训练协议的性能，则尚少被直接追问。

将这几条脉络并置，便显出一处共同的空白。借流强化学习的研究大多依赖多于单点的流场观测，或允许智能体在线反复试错；离线强化学习的方法多在标准基准上验证，鲜少触及单点局部可观测这一物理传感约束；利用特权信息的工作则大多预设训练期的特权确有助益，并设法加以利用。若只有局部感知约束，在线交互仍可能通过试错补偿观测不足；若只有离线学习约束，标准基准又通常不要求策略从物理上受限的单点流速中恢复环境结构；若允许训练期特权信息，价值学习或策略蒸馏还可绕开一部分部署传感不足。三者同时成立时，问题才转化为一个更严格的判别：固定数据中是否已经包含足够信息，使只依赖单点部署观测的策略能够恢复可用的运动规划规律。

这一情形是受尺寸、功耗、成本与安全约束平台的一类典型处境，却至今缺乏系统刻画。它也不是对生物侧线结构的直接仿制；本章关心的是，在无法部署空间分布式流场阵列时，时间上的观测组织和离线数据中的行为目标能否补偿空间信息的缺失。本章即定位于这一交叉处，在共同的部署约束与多随机种子的统计检验下，刻画局部感知约束下可行性的来源及其边界，并分析离线学习内部哪些因素实际支配算法表现。

5.3 问题设定与评估协议

本章三条线索——在线可学性、离线主线与算法对比——共享同一套任务、环境与部署接口。本节固定这一设定，并明确贯穿全章的四条对照轴：奖励目标、流动工况、传感配置与数据采集器。这一设定同时给出中心命题两侧的具体所指：策略在部署时实际掌握的信息，仅是 AUV 单点处的局部流速估计；可供离线学习复用的数据，是既有控制器采集的轨迹；而为系统增添能力的两条具体形态——增设空间探针、向价值网络注入特权观测——也在此获得精确定义。全章结果表格中的奖励、工况与传感维度均以本节为基准。

5.3.1 任务与动力学

本章考虑一类水下自主航行器在卡门涡街（Kármán vortex street）尾流场中执行点到点运动规划的任务。航行器为 REMUS-100 类圆柱形载体（长 $L = 1.6$ m，直径 $d = 0.19$ m，排水质量 $m \approx 32$ kg），其动力学采用 Fossen 框架下完整的六自由度非线性方程组 [Fossen, 2011]，含附加质量、科氏力、横流阻力、桨叶推力与舵面升力，以四阶 Runge-Kutta 积分器在物理步长 $\Delta t_{\text{sim}} = 0.1$ s 上推进；每个决策步含 5 个物理子步，对应控制周期 $\Delta t_{\text{ctrl}} = 0.5$ s。深度由级联 PID 内环维持，使六自由度动力学在水平面退化为有效的三自由度平面运动 $[u, v, r, x_N, y_E, \psi]$ 。

尾流场由二维双弛豫时间格子玻尔兹曼方法离线生成，圆柱直径 $D = 12$ m，输出空间分辨率 $\Delta x = 0.6$ m，记录时长约 360 s（覆盖约九至十个涡旋脱落周期），每回合起始相位在记录区间内均匀随机采样以避免相位过拟合。本章在两个流动工况上考察策略。亚临界工况取来流 $U_\infty = 1.0$ m/s、雷诺数 $\text{Re} = 150$ ，处于严格的二维层流卡门涡街区间，是全章的主工况；临界工况取 $U_\infty = 1.5$ m/s、 $\text{Re} = 250$ ，涡旋更强、脱落更快，专用于刻画策略的失效边界。需说明的是，真实绕流在 $\text{Re} \approx 190$ 处发生三维失稳， $\text{Re} = 250$ 仍采用二维模型是一处明确的建模简化：它略微高估涡旋强度与斯特劳哈尔数，但不改变卡门涡街的定性时空结构。

任务几何以垂直来流方向（ $\pm 20^\circ$ 内随机）的横流穿越为主，目标对水速度上限 $V_{\text{max}} = 1.5$ m/s。两个工况下的速度比 $\lambda = U_\infty/V_{\text{max}}$ 分别为 0.67 与 1.0。当 $\lambda = 1.0$ 时，航行器在自由来流中可用于形成稳定对地位移的速度余量显著收缩，单纯按来流作直线补偿难以保证横流穿越任务中的净位移，因而需要利用尾流的非均匀结构——低速走廊、瞬态反向流与交变横向分量——获得可行运动。每回合起终点距离在 $[40, 90]$ m 内均匀采样，质心进入目标 4 m 半径内判成功，超出流场边界、动力学违规或超时（240 s）判失败。

5.3.2 可部署观测与传感谱系

策略在每个决策步接收的可部署观测 $\mathbf{o}_t$ 由本体状态、目标信息与局部流速三部分拼接而成。本体五维为体轴线速度与偏航率 (u, v, r) 以及以 $(\cos \psi, \sin \psi)$ 编码的艏向（三角编码避免 $\pm \pi$ 跳变）；目标三维为目标在体坐标系下的相对位置 $(\Delta x_b, \Delta y_b)$ 与距离 d ，各量按固定尺度归一化，体坐标系表示使观测对全局朝向具有不变性。流速部分由探针布局决定：每个探针给出其所在位置体坐标系下的单点流速 (u_c, v_c) 。

表 5.1: 本章的三种传感配置。三者均对应 REMUS-100 平台上物理可实现的传感器； s_0 是全章策略网络共享的可部署主轴， s_1 与 s_2 仅作参考上界。单步观测维度为 8（本体 5 + 目标 3）+ $2n_p$ （ n_p 为探针数），到达导向奖励另加 2 个回合级上下文通道（见正文）。

布局	探针位置 (体轴, m)	物理对应传感器	角色 / 感知类型
s_0	(0, 0)	DVL 1200 kHz 水追踪	可部署主轴；单点瞬时流速
s_1	(0, 0), (4.5, 0)	+ 2 MHz 短程 ADCP	参照上界；短程预警 (~ 3 步)
s_2	(0, 0), (5, 0), (8, ± 4)	+ 1 MHz 长程 ADCP	参照上界；长程预警 (~ 7 步) + 侧向梯度

本章涉及三种探针布局，均对应 REMUS-100 平台上物理可实现的传感配置（表 5.1）。 s_0 仅在机体质心 (0, 0) 设单一探针，对应平台标配的多普勒测速仪（DVL，1200 kHz）水追踪模式所能给出的最弱流场感知——它只测得当前位置的瞬时流速，是单点流速测量的下界。这一布局是本章策略网络（actor）在三条线索中共享的部署主轴，也正是中心命题中策略可资利用的已有信息的物理载体。 s_1 在 s_0 之外增设一处前向探针 (4.5, 0)，对应一台 2 MHz 短程 ADCP，提供约三个控制步的轴向预警； s_2 进一步增设近端与两侧探针 (5, 0)、(8, ± 4)，对应 1 MHz 长程 ADCP，兼具约七步的轴向预警与侧向流速梯度感知。 s_1 与 s_2 在本章中仅作物理可对应的参照上界，用以界定 s_0 与更丰富空间感知之间的差距；本节不预设额外空间感知对可部署性能的必要性。

观测在送入策略前外接 $k = 4$ 步历史堆叠，以时间维度补偿单点感知缺失的空间信息。本章奖励设定在观测构成上仅有一处差异：到达导向奖励额外附带两个回合级上下文通道（已耗时间占比与归一化初始距离），早期效率导向奖励则无；这一差异来自到达导向奖励对时间语义与初始距离尺度的显式编码。因此 s_0 单步观测在早期效率导向奖励下为 10 维、在到达导向奖励下为 12 维，经 $k = 4$ 历史堆叠后分别为 40 维与 48 维；各结果表中的观测维度均以此为准。两类奖励在复现索引中的标识分别为 `efficiency_v2` 与 `arrival_v2`。

5.3.3 特权观测（仅价值网络）

为支持非对称 Actor-Critic [Pinto et al., 2018] 协议下的对照，环境另给出一路特权观测 $\mathbf{o}_t^{\text{priv}} \in \mathbb{R}^2$ 。它是 §5.1 中抽象引入的特权信息在本任务中的具体所指，即体坐标系下的沿机体采样等效来流 $(u_{\text{eq}}, v_{\text{eq}})$ 。这里的等效来流由沿 AUV 机体纵轴若干代表点采样平均得到，而非全场流场输入；其数值由沿机体纵轴 $N = 5$ 个等距采样点的世界系流速等权平均、再投影至体坐标系给出：

$$\mathbf{o}_t^{\text{priv}} = (u_{\text{eq}}, v_{\text{eq}}) = \frac{1}{N} \sum_{i=1}^N R_{wb}(\psi) \mathbf{u}_{\text{world}}(\mathbf{p}^{(0)} + \xi_i L \hat{\mathbf{e}}_{\text{body}}), \quad \xi_i \in \{-0.4, -0.2, 0, 0.2, 0.4\}. \quad (5.1)$$

其中 $R_{wb}(\psi)$ 为世界系到体坐标系的旋转矩阵。该量等价于求解六自由度方程时实际作用于载体的有效来流，因而是物理含义明确的动力学有效输入，而非与动力学无关的任意隐藏变量；它在训练期可得、部署期不可得，恰是特权信息的定义性特征。

据此区分两种训练协议。可部署协议下，策略网络与价值网络（critic）都只读 $\mathbf{o}_t$ ，与本章定义的 REMUS-100 可部署传感接口一致；特权协议下，价值网络额外读取 $\mathbf{o}_t^{\text{priv}}$ ，而策略网络始终只

读 $\mathbf{o}_t$ 。评估与部署阶段价值网络已被弃用， $\mathbf{o}_t^{\text{priv}}$ 不出现在执行回路中，故两种协议训练所得策略在部署时的传感依赖完全一致。图 5.1 示意了任务几何与两种协议下两个网络的传感边界。这一对照正是本章检验特权信息是否必需的实验杠杆：若可部署协议达到与特权协议相近的性能，则训练期额外提供的等效流速信息对部署性能并非必需。

5.3.4 动作、奖励与终止

航行器的动作为二维连续向量 $\mathbf{a}_t = (a_\psi, a_n) \in [-1, 1]^2$ 。在绝对航向模式下， a_ψ 映射为期望偏航角参考 $\psi_{\text{ref}} = a_\psi \cdot \pi$ ，由内层 PD 控制器跟踪； a_n 映射为归一化的螺旋桨转速指令。这两个分量分别支配航向选择与推进强度，构成策略借流机动的全部操纵自由度。

本章正式采用到达导向奖励作为任务成功率分析的主奖励设定。为说明其设计必要性，先回顾早期离线主线所使用的效率导向奖励。该奖励以时间惩罚和目标距离进度整形为主体，并叠加轻量软安全代价与终止奖励；它适合在早期行为约束离线方法之间保持同口径比较，但在较难任务中可能产生目标错配：当策略难以到达目标时，持续累积的时间惩罚可能使提前出界获得比长时间接近目标更高的回报。

早期效率导向奖励由四项叠加构成，即每步时间惩罚、基于目标距离差的进度整形、轻量软安全惩罚以及终止奖励：

$$r_t = \underbrace{-c \Delta t_{\text{ctrl}}}_{\text{时间惩罚}} + \underbrace{k_p (d_{t-1} - d_t)}_{\text{进度整形}} - \underbrace{k_s c_t^{\text{safety}}}_{\text{软安全惩罚}} + r_{\text{term}}, \quad c = 2.0 \text{ s}^{-1}, \quad k_p = 1.0, \quad k_s = 0.25, \quad (5.2)$$

终止奖励 r_{term} 为到达目标的 +100 或失败的 -20，超界、动力学违规与超时均判失败； c_t^{safety} 为边界、姿态、速度与角速度风险的统一软代价。尽管该软安全项已对贴近边界的行为给出惩罚，其权重相对每步时间惩罚与终止项较弱。在较难任务中，这一奖励结构可能诱发一种退化模式：当目标在当前策略下难以到达时，持续累积的每步时间惩罚使提前出界成为回报更优的选择，失败惩罚 -20 与轻量安全项不足以抵消长时间漂行累积的时间代价，策略遂可能贴边滑行并尽早触发出界终止，使回合回报与任务成功率之间出现错配。这一沿边界提前失败的回报偏置暴露出早期效率导向奖励与任务主指标的错配，促成了向到达导向奖励的迁移。

基于这一失配，在线可学习性、泛化边界考察与算法比较统一采用到达导向奖励。该奖励不再把“更快结束”作为隐含优化方向，而是显式区分到达、超时与硬失败，并通过早失败惩罚抑制快速出界。每步奖励给出归一化的进度整形、微弱的时间代价与软安全惩罚：

$$r_t^{\text{step}} = w_p \frac{d_{t-1} - d_t}{d_0} - w_\tau \frac{\Delta t_{\text{ctrl}}}{T_{\text{max}}} - w_s c_t^{\text{safety}}, \quad (5.3)$$

回合终止时按语义附加终止项

$$r^{\text{term}} = \begin{cases} +R_{\text{succ}}, & \text{到达目标,} \\ -R_{\text{to}} - R_d \rho, & \text{超时,} \\ -R_{\text{fail}} - R_{\text{early}}(1 - \eta) - R_d \rho, & \text{硬失败,} \end{cases} \quad (5.4)$$

其中 $d_0 = \max(d_{\text{init}}, 10 \text{ m})$ 为带下界保护的初始目标距离, $\eta = \text{clip}(t/T_{\text{max}}, 0, 1)$ 为已耗时间占比, $\rho = \text{clip}(d_t/d_0, 0, 2)$ 为终止距离比; 本章任务的起终点距离为 40–90 m, 故该下界保护在正式评估分布内不激活。权重取 $w_p = 50$ 、 $w_\tau = 5$ 、 $w_s = 2$, 终止系数 $R_{\text{succ}} = R_{\text{fail}} = R_{\text{early}} = 100$ 、 $R_{\text{to}} = R_d = 50$ 。

两处设计共同抑制了上述提前失败偏置。硬失败的早失败惩罚 $R_{\text{early}}(1 - \eta)$ 随已耗时间递减, 使越早出界惩罚越重; 该奖励设计满足的核心约束是, 成功优于超时、超时优于硬失败, 尤其快速出界不再优于接近目标的超时回合。同时, 归一化的进度与时间项把每步信号压到低于终止项的量级, 使任务语义主要由到达、超时与硬失败三类终止项表达, 而不再由累积步惩罚主导。代价是奖励不再是纯势函数整形: 到达、超时与硬失败的非势函数终止项直接编码任务语义, 这一取舍意在换取与主指标对齐的可学习信号。两个回合级量 (已耗时间占比 η 与按固定距离尺度归一化的初始目标距离) 须进入观测, 否则同一转移会因隐藏的已耗时间或初始距离获得不同回报, 破坏价值函数的马尔可夫性; 这正是到达导向奖励观测较早期效率导向奖励多两维的原因 (§5.3.2)。早期效率导向奖励保留在离线主线中, 仅用于与既有实验结果保持同口径可比; 其回报数值不与到达导向奖励下的回报作直接比较。跨设定讨论只限于任务成功率、部署约束、信息利用和失效边界等机制性结论。

5.3.5 数据集

离线数据由若干行为策略在上述环境中采集。目标直指参照与横流补偿参照是严格的 s_0 非学习控制器, 前者直接朝目标航行并固定油门, 后者依单点流速的体坐标系横向分量做反向偏航补偿; 二者与待训练策略共享最弱传感协议。世界坐标系流速补偿参照作为理想化的可部署流速补偿基线, 使用导航坐标系下的当前等效流速估计修正期望对地航迹; 它不读取未来流场或全场候选走廊, 但其信息口径强于仅由策略观测向量直接解码的严格单点观测控制器。全场走廊参照读取仿真器尾流场, 为若干候选走廊打分并跟踪最优航迹, 本身不可部署, 仅用于生成高质量的参照数据。这里的全场走廊参照是行为数据采集器, 不等同于 §5.3.3 中仅供价值网络读取的特权观测协议。

除上述规则型策略外, 本章还引入由在线 SAC 策略检查点构成的采集器族。沿用离线强化学习基准构造数据的通行做法, 从一条 SAC 训练轨迹的不同阶段截取检查点, 得到质量递增的四档采集器 (随机、中等、中等偏专家、专家), 其行为策略与 s_0 部署传感保持一致。这一数据源服务于算法对比线索, 用以考察算法表现如何随数据质量变化, 并提供规则型采集器覆盖不到的中等质量工况。

表 5.2 汇总本章主要离线数据集及其在四条对照轴——采集器、奖励设定、工况、传感——上的坐标, 并标明各自用途。所有数据集统一采用 s_0 传感、 $k = 4$ 历史与横流穿越几何, 每集 1000 回合 (早期效率导向历史集另含一个 2000 回合预算); 差异集中在采集器 (数据质量)、奖励目标与流动工况三轴。公共数据集的转移规模列于 §5.3.7, 其余逐档统计随相应实验条件报告。

表 5.2: 本章主要离线数据集及其在四条对照轴上的坐标。所有数据集共享 s_0 传感与 $k = 4$ 历史堆叠；观测维度由奖励设定决定（历史效率导向奖励为 40 维、到达导向奖励为 48 维）。FQL 的多模态与含噪变体、SAC 各档统计作为相应实验条件的一部分另行报告。

采集器	奖励设定	工况	回合数	用途
横流补偿参照	历史效率导向奖励	亚临界 Re150 / u10	1000 / 2000	历史效率导向离线数据
世界坐标系流速补偿参照	历史效率导向奖励	亚临界 Re150 / u10	1000	历史效率导向协议对照
横流补偿参照	到达导向奖励	亚临界 Re150 / u10	1000	亚临界到达任务数据
全场走廊参照	到达导向奖励	临界 Re250 / u15	1000	临界到达任务数据
全场走廊参照	到达导向奖励	亚临界 Re150 / u10	1000	高质量到达任务数据
SAC 检查点（四档）	到达导向奖励	亚临界 Re150 / u10	1000	SAC 检查点数据质量轴

5.3.6 评估协议

所有方法在固定评估集（manifest）上以确定性策略评估。评估集是一组预先采样、各方法共用的起终点与流场相位配置，使不同算法、不同种子的成功率严格可比，其任务分布与对应数据采集时一致。主工况评估每种子 100 回合，较难工况与在线训练过程中的历史检查点评估每种子 30 回合；主指标为任务成功率，即质心进入目标半径内的回合占比。

成对协议的比较（如可部署协议与特权协议）以随机种子为主要推断单位：每个种子先在固定评估集上得到成功率，再比较种子级均值。两组独立的种子级成功率均值之差以 Welch 不等方差 t 检验判别 [Welch, 1947]，自由度按 Welch-Satterthwaite 公式计算。回合级配对自助法仅作为固定评估集下对配对任务实例的敏感性复核 [Efron and Tibshirani, 1993]，即在保持方法配对关系的前提下对评估任务实例重采样，报告均值差的百分位置信区间，用于检查结论是否依赖少数起终点或流场相位；它不替代种子级推断，也不把回合视为独立推断样本。当 t 检验不拒绝等均值且自助置信区间跨越零时，本章表述为未检测到统计显著差异；若进一步作出性能相近或等价判断，则同时要求种子级效应量落在相应结果节预先给出的实践容忍范围内。

对成功率为零的负面结果，单凭点估计不足以界定其上界。本章按 rule-of-three 给出此类零计数的 95% 置信上界约 $3/n$ [Jovanovic and Levy, 1997]，使“完全失败”这一结论本身带有量化的统计强度，与正面结果同台呈现而非降格为附带说明。随机种子取固定数量的一组，全章各线在其协议内保持一致；正文报告种子数量和每种子评估回合数，具体随机种子编号保留在复现实验配置与结果记录中。

5.3.7 实施细节与可复现性

观测各通道的归一化常数为：速度尺度 2.0 m/s（本体与流速通道共用）、偏航率尺度 1.0 rad/s、距离尺度 200 m。到达导向奖励的两个回合级上下文通道分别为已耗时间占比 $\eta \in [0, 1]$ 与按 200 m 归一化的初始目标距离。特权观测 $\mathbf{o}^{\text{priv}} = [u_{\text{eq}}, v_{\text{eq}}]$ 维度为 2、不随历史堆叠，离线数据以 $\mathbf{o}^{\text{priv}}$ 与其后继 $\mathbf{o}'^{\text{priv}}$ 两列随转移一并记录，以支持接收特权观测的价值网络协议。


公共数据集的规模如下：横流补偿参照的 1000 / 2000 回合集分别约含 2.4×10^5 / 4.8×10^5

表 5.3: 共享设定的复现索引。表中列出本节直接承担的公共数据与评估入口；FQL 多模态、含噪声变体及 SAC 四档的逐档统计随相应实验条件报告。

用途	数据 / 评估入口	奖励与工况	观测	种子 / 回合
TD3+BC / ReBRAC: 历史效率导向离线主线	crosscomp_s0_h4_efficiency_v2_re150_u10cross_ep1000/2000	历史效率导向奖励, Re150 / u10	$s_0, h = 4, 40\text{-D}$	5 seeds; 100 eval ep
TD3+BC / ReBRAC: 可部署-特权协议对照	worldcomp_s0_h4_efficiency_v2_re150_u10cross_ep1000	历史效率导向奖励, Re150 / u10	$s_0, h = 4, 40\text{-D}$	5 seeds; 100 eval ep
亚临界到达任务数据	crosscomp_s0_h4_arrival_v2_re150_u10cross_ep1000	到达导向奖励, Re150 / u10	$s_0, h = 4, 48\text{-D}$	固定种子组
临界到达任务数据	privileged_s0_h4_arrival_v2_re250_u15cross_ep1000	到达导向奖励, Re250 / u15	$s_0, h = 4, 48\text{-D}$	固定种子组
主工况评估	single_u10_cross_tgt15	与训练数据一致	manifest 固定起终点与相位	100 ep / seed
较难工况评估	single_u15 系列	Re250 / u15	manifest 固定起终点与相位	30 ep / seed

条转移, 世界坐标系流速补偿参照的 1000 回合集约 2.0×10^5 条。到达导向奖励下的基线采集器与 SAC 检查点采集器同样以 1000 回合为基本规模; SAC 四档采集器的逐档转移条数、行为质量与失败模式分布在算法对比分析中给出。

Welch-Satterthwaite 自由度由两组样本方差与样本量按标准公式计算; 配对自助法取 $B = 10^4$ 次回合级重采样给出百分位置信区间。主工况评估集为 **single_u10_cross_tgt15** (每种子 100 回合), 较难工况评估集为 **single_u15** 系列 (每种子 30 回合)。离线主线固定 5 个随机种子, 泛化边界与算法对比在各自协议内使用固定种子组; 具体随机种子编号不作为正文论证对象, 保留于复现实验配置。



(b) Deployable vs. privileged sensor sampling

Body-frame (not to scale)




图 5.1: 任务与传感协议示意。(a) 二维双弛豫时间格子玻尔兹曼方法离线生成的卡门涡街尾流场 (亚临界工况 $U_\infty = 1.0$ m/s、 $Re = 150$ 、湍流强度 5%) 某一帧的涡量背景, 叠加 REMUS-100 体示意 (黄色椭圆, 红色箭头为体轴朝向) 与横流穿越任务目标 (绿色五角星)。(b) 体坐标系下两种传感抽样协议: 蓝色实心圆 s_0 是部署可得的单点 DVL 水追踪, 策略网络在两种协议下都只读此通道; 红色菱形为沿体轴的 $\xi_i \in \{-0.4, -0.2, 0, +0.2, +0.4\} \cdot L$ 五个等距采样点, 等权平均后给出沿机体采样等效来流 $\mathbf{o}^{priv} = [u_{eq}, v_{eq}]$, 仅在特权协议训练阶段被价值网络读取, 部署阶段不可用 ((5.1))。

参考文献

- Dian Chen, Brady Zhou, Vladlen Koltun, and Philipp Krähenbühl. Learning by cheating. In *Proceedings of the Conference on Robot Learning (CoRL)*, volume 100 of *Proceedings of Machine Learning Research*, pages 66–75, 2020.
- Simona Colabrese, Kristian Gustavsson, Antonio Celani, and Luca Biferale. Flow navigation by smart microswimmers via reinforcement learning. *Physical Review Letters*, 118:158004, 2017. doi: 10.1103/PhysRevLett.118.158004.
- Sheryl Coombs, Joseph Bak-Coleman, and John Montgomery. Rheotaxis revisited: A multi-behavioral and multisensory perspective on how fish orient to flow. *Journal of Experimental Biology*, 223:jeb223008, 2020. doi: 10.1242/jeb.223008.
- Valentina Di Santo and Elsa Goerig. Swimming smarter, not harder: Fishes exploit habitat heterogeneity to increase locomotor performance. *Journal of Experimental Biology*, 228(Suppl_1): JEB247918, 2025. doi: 10.1242/jeb.247918.
- Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Monographs on Statistics and Applied Probability. Chapman & Hall, New York, 1993.
- Hao-Dong Feng, De-Hua Yuan, Jia-Liang Miao, et al. Efficient navigation of a robotic fish swimming across the vortical flow field. *Journal of Hydrodynamics*, 36:1118–1129, 2025. doi: 10.1007/s42241-025-0103-5.
- Yoav Flato, Roi Harel, Aviv Tamar, Ran Nathan, and Tsevi Beatus. Revealing principles of autonomous thermal soaring in windy conditions using vulture-inspired deep reinforcement learning. *Nature Communications*, 15:4942, 2024. doi: 10.1038/s41467-024-48670-x.
- Thor I. Fossen. *Handbook of Marine Craft Hydrodynamics and Motion Control*. John Wiley & Sons, 2011.
- Scott Fujimoto and Shixiang Shane Gu. A minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

- Scott Fujimoto, David Meger, and Doina Precup. Off-policy deep reinforcement learning without exploration. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019.
- Peter Gunnarson, Ioannis Mandralis, Guido Novati, Petros Koumoutsakos, and John O. Dabiri. Learning efficient navigation in vortical flow fields. *Nature Communications*, 12:7143, 2021. doi: 10.1038/s41467-021-27015-y.
- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018.
- Yusheng Jiao, Haotian Hang, Josh Merel, and Eva Kanso. Sensing flow gradients is necessary for learning autonomous underwater navigation. *Nature Communications*, 16:3044, 2025. doi: 10.1038/s41467-025-58125-6.
- Borko D. Jovanovic and Paul S. Levy. A look at the rule of three. *The American Statistician*, 51(2):137–139, 1997. doi: 10.1080/00031305.1997.10473947.
- Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit q-learning. In *International Conference on Learning Representations (ICLR)*, 2022.
- Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- Sergey Levine, Aviral Kumar, George Tucker, and Justin Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems, 2020.
- Liang Li, Máté Nagy, Jacob M. Graving, Joseph Bak-Coleman, Guangming Xie, and Iain D. Couzin. Vortex phase matching as a strategy for schooling in robots and in fish. *Nature Communications*, 11:5408, 2020. doi: 10.1038/s41467-020-19086-0.
- James C. Liao. Fish swimming efficiency. *Current Biology*, 32(12):R666–R671, 2022. doi: 10.1016/j.cub.2022.04.073.
- Selim Mecanna, Aurélie Loisy, and Christophe Eloy. A critical assessment of reinforcement learning methods for microswimmer navigation in complex flows. *European Physical Journal E*, 48:58, 2025. doi: 10.1140/epje/s10189-025-00522-2.
- Navid Mousavi, Jingran Qiu, Bernhard Mehlig, Lihao Zhao, and Kristian Gustavsson. Efficient survival strategy for zooplankton in turbulence. *Physical Review Research*, 6:L022034, 2024. doi: 10.1103/PhysRevResearch.6.L022034.

- Seohong Park, Qiyang Li, and Sergey Levine. Flow q-learning, 2025.
- Lerrel Pinto, Marcin Andrychowicz, Peter Welinder, Wojciech Zaremba, and Pieter Abbeel. Asymmetric actor critic for image-based robot learning. In *Proceedings of Robotics: Science and Systems (RSS)*, 2018.
- Jingran Qiu, Navid Mousavi, Kristian Gustavsson, and Bernhard Mehlig. Navigation of microswimmers in steady flow: The importance of symmetries. *Journal of Fluid Mechanics*, 932:A10, 2022. doi: 10.1017/jfm.2022.258.
- Denis Tarasov, Vladislav Kurenkov, Alexander Nikulin, and Sergey Kolesnikov. Revisiting the minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- Vladimir Vapnik and Akshay Vashist. A new learning paradigm: Learning using privileged information. *Neural Networks*, 22(5–6):544–557, 2009. doi: 10.1016/j.neunet.2009.06.042.
- Siddhartha Verma, Guido Novati, and Petros Koumoutsakos. Efficient collective swimming by harnessing vortices through deep reinforcement learning. *Proceedings of the National Academy of Sciences (PNAS)*, 115(23):5849–5854, 2018. doi: 10.1073/pnas.1800923115.
- B. L. Welch. The generalization of ‘student’s’ problem when several different population variances are involved. *Biometrika*, 34(1–2):28–35, 1947. doi: 10.1093/biomet/34.1-2.28.
- Yi Zhu, Jian-Hua Pang, and Fang-Bao Tian. Point-to-point navigation of a fish-like swimmer in a vortical flow with deep reinforcement learning. *Frontiers in Physics*, 10:870273, 2022. doi: 10.3389/fphy.2022.870273.